

## ① EM アルゴリズム

## 1 EM アルゴリズム

- EM アルゴリズムの解釈
- 混合ガウス分布の再解釈
- K-Means 法との関連
- 一般の EM アルゴリズム
- MAP 推定に対する EM アルゴリズム
- EM アルゴリズムの拡張
- EM アルゴリズムに関する補足
- 逐次型の EM アルゴリズム

# EM アルゴリズムの解釈

- ここまでの話の流れ

- 1 ソフト割り当てを実現するために、確率モデル (混合ガウスモデル) を導入した
- 2 混合ガウス分布のパラメータを、最尤推定により直接求めるのは困難であった
- 3 潜在変数を導入して再度定式化を行い、混合ガウス分布に対する EM アルゴリズムを自然に導出した
- 4 EM アルゴリズムの中で、潜在変数は、負担率 (事後分布) の形で登場しただけであった ( $\gamma(z_{ik}) = p(z_k = 1|x_i)$ )

- これからの話の流れ

- 潜在変数が果たす重要な役割を明確にする
- そのうえで、混合ガウス分布の場合をもう一度見直す

- EM アルゴリズムの目的
  - 潜在変数をもつ確率モデルについて、パラメータの最尤解を求める
- 対数尤度関数の記述 (一般的な場合)
  - 全ての観測データをまとめた、データ行列を  $\mathbf{X}$  とする (第  $i$  行が  $\mathbf{x}_i^T$ )
  - 全ての潜在変数をまとめた行列を  $\mathbf{Z}$  とする (第  $i$  行が  $\mathbf{z}_i^T$ )
  - 確率モデルの全てのパラメータを、 $\boldsymbol{\theta}$  と表す
- 対数尤度関数は次のようになる

$$\ln p(\mathbf{X}|\boldsymbol{\theta}) = \ln \left( \sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta}) \right) \quad (1)$$

# EM アルゴリズムの解釈

- 潜在変数  $z$  が連続変数の場合は

$$\ln p(\mathbf{X}|\boldsymbol{\theta}) = \ln \left( \int p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta}) d\mathbf{Z} \right) \quad (2)$$

のように、単に総和を積分に置き換えればよい

- これ以降、離散潜在変数のみを扱うが、総和を積分に置き換えれば、ここでの議論は、連続潜在変数についても同様に成立
- 何が問題だったか
  - 対数の中に、潜在変数に関する総和が含まれる (log-sum の形)
  - 総和が存在するので、対数  $\ln$  が、周辺分布  $p(\mathbf{X}|\boldsymbol{\theta})$  に直接作用することが妨げられる
  - その結果として、対数尤度関数が複雑な形となる

# EM アルゴリズムの解釈

- 完全データと不完全データ
  - $X$  だけでなく、 $Z$  も観測できるとする
  - $\{X, Z\}$  の組を、**完全データ集合**という
  - 実際には  $X$  しか見えないので、実際の観測データ  $X$  は**不完全**である
- $Z$  に関する知識は、潜在変数についての事後確率分布  $p(Z|X, \theta)$  のみからしか得られない

## 重要な仮定と考え方

- 1 完全データ対数尤度関数  $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  の最大化は、 $\ln p(\mathbf{X}|\boldsymbol{\theta})$  の最大化よりも、簡単であると仮定
- 2  $\ln p(\mathbf{X}|\boldsymbol{\theta})$  の代わりに、完全データ対数尤度関数  $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  を最大化したいが、 $\mathbf{Z}$  に関する情報は  $\ln p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})$  からしか得られない
- 3 そのため、完全データ対数尤度関数  $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  は使えない
- 4 そこで、事後確率分布  $p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})$  による、 $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  の期待値を最大化することを考える
- 5 これが、EM アルゴリズムの考え方である

- EM アルゴリズムへの落とし込み
  - パラメータ  $\theta$  を適当に初期化する
  - **E ステップ**では、事後確率分布  $p(\mathbf{Z}|\mathbf{X}, \theta^{\text{old}})$  を、現在のパラメータ  $\theta^{\text{old}}$  を使って求める
  - $p(\mathbf{Z}|\mathbf{X}, \theta^{\text{old}})$  を、M ステップでの期待値の計算に使う
  - **M ステップ**では、完全データ対数尤度関数  $\ln p(\mathbf{X}, \mathbf{Z}|\theta)$  の、事後確率分布  $p(\mathbf{Z}|\mathbf{X}, \theta^{\text{old}})$  に関する期待値  $\mathcal{Q}(\theta, \theta^{\text{old}})$  を計算

$$\mathcal{Q}(\theta, \theta^{\text{old}}) = \sum_{\mathbf{Z}} p(\mathbf{Z}|\mathbf{X}, \theta^{\text{old}}) \ln p(\mathbf{X}, \mathbf{Z}|\theta) \quad (3)$$

連続潜在変数の場合は次のようになる

$$\mathcal{Q}(\theta, \theta^{\text{old}}) = \int p(\mathbf{Z}|\mathbf{X}, \theta^{\text{old}}) \ln p(\mathbf{X}, \mathbf{Z}|\theta) d\mathbf{Z} \quad (4)$$



# EM アルゴリズムの解釈

- 上式において、 $p(\mathbf{Z}|\mathbf{X}, \theta^{\text{old}})$  におけるパラメータ  $\theta^{\text{old}}$  は、変数ではなく定数であることに注意
- 更に、 $Q(\theta, \theta^{\text{old}})$  を  $\theta$  について最大化することで、新たなパラメータの推定値  $\theta^{\text{new}}$  を得る

$$\theta^{\text{new}} = \arg \max_{\theta} Q(\theta, \theta^{\text{old}}) \quad (5)$$

- 注意点
  - $Q(\theta, \theta^{\text{old}})$  において、対数  $\ln$  は、同時分布  $p(\mathbf{X}, \mathbf{Z}|\theta)$  に直接作用していることに注意
  - これにより、期待値の計算が簡単になることが期待される
- なぜ事後確率分布  $p(\mathbf{Z}|\mathbf{X}, \theta)$  についての期待値なのか
  - 幾分恣意的にみえるが、後ほど、期待値を取ることの正当性が明らかになる

## 一般の EM アルゴリズム

- 観測変数  $\mathbf{X}$  と、潜在変数  $\mathbf{Z}$  の同時分布  $p(\mathbf{X}, \mathbf{Z}|\theta)$  が与えられているとする
- 目的は、尤度関数  $p(\mathbf{X}|\theta)$  を、パラメータ  $\theta$  について最大化することである

- パラメータを  $\theta^{\text{old}}$  に初期化する
- E ステップ**: 事後確率分布  $p(\mathbf{Z}|\mathbf{X}, \theta^{\text{old}})$  を計算する

- 3 M ステップ: 次式で与えられる  $\theta^{\text{new}}$  を計算する

$$\theta^{\text{new}} = \arg \max_{\theta} Q(\theta, \theta^{\text{old}}) \quad (6)$$

但し

$$Q(\theta, \theta^{\text{old}}) = \sum_{\mathbf{Z}} p(\mathbf{Z}|\mathbf{X}, \theta^{\text{old}}) \ln p(\mathbf{X}, \mathbf{Z}|\theta) \quad (7)$$

- 4 対数尤度の変化量、あるいはパラメータの変化量を見て、収束性を判定
- 5 収束条件を満たしていなければ、(2) に戻る

$$\theta^{\text{old}} \leftarrow \theta^{\text{new}} \quad (8)$$

## 1 EM アルゴリズム

- EM アルゴリズムの解釈
- 混合ガウス分布の再解釈
- K-Means 法との関連
- 一般の EM アルゴリズム
- MAP 推定に対する EM アルゴリズム
- EM アルゴリズムの拡張
- EM アルゴリズムに関する補足
- 逐次型の EM アルゴリズム

# 混合ガウス分布の再解釈

- 先程の EM アルゴリズムの解釈で、混合ガウス分布を見直す
- これまでの話の流れ
  - 目的は、対数尤度関数  $\ln p(\mathbf{X}|\boldsymbol{\theta})$  の最大化であった
  - しかし、対数の中に総和が出現するため、最尤推定が困難であった
  - そこで、離散潜在変数  $\mathbf{Z}$  を導入し、完全データ集合  $\{\mathbf{X}, \mathbf{Z}\}$  に関する尤度の最大化を考える

# 混合ガウス分布の再解釈

- 完全データ集合  $\{X, Z\}$  に関する尤度の最大化
  - 完全データ尤度関数  $p(X, Z|\theta)$  は次のようになる

$$\begin{aligned} & p(X, Z|\theta) \\ = & p(Z|\theta)p(X|Z, \theta) \\ = & \prod_i p(z_i|\theta)p(x_i|z_i, \theta) \\ = & \prod_i \left( \prod_k \pi_k^{z_{ik}} \right) \left( \prod_k \mathcal{N}(x_i|\mu_k, \Sigma_k)^{z_{ik}} \right) \\ = & \prod_i \prod_k \pi_k^{z_{ik}} \mathcal{N}(x_i|\mu_k, \Sigma_k)^{z_{ik}} \\ = & \prod_i \prod_k (\pi_k \mathcal{N}(x_i|\mu_k, \Sigma_k))^{z_{ik}} \end{aligned} \tag{9}$$

# 混合ガウス分布の再解釈

- ここで、データ点  $x_i$  に対応する潜在変数を  $z_i$ 、また  $z_i$  の  $k$  番目の要素を  $z_{ik}$  とする
- データ点  $x_i, z_i$  は、 $p(X, Z|\theta)$  から独立にサンプルされているとする (このとき、要素ごとの積として書ける)
- 対数を取ると次のようになる

$$\begin{aligned} & \ln p(X, Z|\theta) \\ &= \ln \left( \prod_i \prod_k (\pi_k \mathcal{N}(x_i | \mu_k, \Sigma_k))^{z_{ik}} \right) \\ &= \sum_i \sum_k \ln ((\pi_k \mathcal{N}(x_i | \mu_k, \Sigma_k))^{z_{ik}}) \\ &= \sum_i \sum_k z_{ik} \ln (\pi_k \mathcal{N}(x_i | \mu_k, \Sigma_k)) \\ &= \sum_i \sum_k z_{ik} (\ln \pi_k + \ln \mathcal{N}(x_i | \mu_k, \Sigma_k)) \end{aligned} \tag{10}$$

# 混合ガウス分布の再解釈

- $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  を、元々最大化しようとしていた  $\ln p(\mathbf{X}|\boldsymbol{\theta})$  と比較する

$$\ln p(\mathbf{X}|\boldsymbol{\theta}) = \sum_i \ln \left( \sum_k \pi_k \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right) \quad (11)$$

- $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  と  $\ln p(\mathbf{X}|\boldsymbol{\theta})$  を比較すると、対数  $\ln$  と、総和  $\sum_k$  の、**順番が入れ替わっている**
- そして、対数  $\ln$  が、ガウス分布  $\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma})$  に**直接作用している**
- よって、 $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  の最大化は、 $\ln p(\mathbf{X}|\boldsymbol{\theta})$  の最大化よりも、**遥かに容易である** (そして、パラメータは**陽な形で解ける**)
- そこで、 $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  を最大化するようなパラメータを求めてみる



# 混合ガウス分布の再解釈

- $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  の  $\boldsymbol{\mu}_k$  に関する最大化
  - 以下のように、 $\boldsymbol{\mu}_k$  で微分して 0 とおけば、簡単に解ける
  - ガウス分布の微分については、先程の EM アルゴリズムの導出時に求めたものを利用している

$$\begin{aligned} & \frac{\partial}{\partial \boldsymbol{\mu}_k} \ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta}) \\ &= \frac{\partial}{\partial \boldsymbol{\mu}_k} \left( \sum_i \sum_k z_{ik} (\ln \pi_k + \ln \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)) \right) \\ &= \sum_i \frac{\partial}{\partial \boldsymbol{\mu}_k} \left( \sum_k z_{ik} (\ln \pi_k + \ln \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)) \right) \\ &= \sum_i \frac{\partial}{\partial \boldsymbol{\mu}_k} z_{ik} (\ln \pi_k + \ln \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)) \\ &= \sum_i z_{ik} \frac{\partial}{\partial \boldsymbol{\mu}_k} \ln \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \end{aligned}$$

# 混合ガウス分布の再解釈

$$\begin{aligned} &= \sum_i z_{ik} \frac{\partial}{\partial \boldsymbol{\mu}_k} \ln \left( \frac{1}{(2\pi)^{\frac{D}{2}}} \frac{1}{|\boldsymbol{\Sigma}_k|^{\frac{1}{2}}} \right. \\ &\quad \left. \exp \left\{ -\frac{1}{2} (\mathbf{x}_i - \boldsymbol{\mu}_k)^T \boldsymbol{\Sigma}_k^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_k) \right\} \right) \\ &= \sum_i z_{ik} \frac{\partial}{\partial \boldsymbol{\mu}_k} \left( -\frac{D}{2} \ln 2\pi - \frac{1}{2} \ln |\boldsymbol{\Sigma}_k| \right. \\ &\quad \left. - \frac{1}{2} (\mathbf{x}_i - \boldsymbol{\mu}_k)^T \boldsymbol{\Sigma}_k^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_k) \right) \\ &= \sum_i z_{ik} \frac{\partial}{\partial \boldsymbol{\mu}_k} \left( -\frac{1}{2} (\mathbf{x}_i - \boldsymbol{\mu}_k)^T \boldsymbol{\Sigma}_k^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_k) \right) \\ &= \sum_i z_{ik} \boldsymbol{\Sigma}_k^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_k) = 0 \end{aligned} \tag{12}$$

これより

$$\sum_i z_{ik} \boldsymbol{\Sigma}_k^{-1} \boldsymbol{\mu}_k = \sum_i z_{ik} \boldsymbol{\Sigma}_k^{-1} \mathbf{x}_i \tag{13}$$

# 混合ガウス分布の再解釈

であるから、両辺に左から  $\Sigma_k$  を掛けて

$$\begin{aligned}\sum_i z_{ik} \mu_k &= \sum_i z_{ik} \mathbf{x}_i \\ \mu_k \sum_i z_{ik} &= \sum_i z_{ik} \mathbf{x}_i \\ \mu_k &= \frac{1}{\sum_i z_{ik}} \sum_i z_{ik} \mathbf{x}_i\end{aligned}\tag{14}$$

のようになる

- 上式をみると、完全データ  $\{X, Z\}$  について、 $\mu_k$  は陽な形で求まっていることが分かる
- 但し実際は  $Z$  が分からないので、 $z_{ik}$  をどうにかして得る必要がある

# 混合ガウス分布の再解釈

- $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  の  $\Sigma_k$  に関する最大化
  - $\Sigma_k$  について微分して 0 とおくと、次のようになる

$$\begin{aligned}& \frac{\partial}{\partial \Sigma_k} \ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta}) \\&= \sum_i z_{ik} \frac{\partial}{\partial \Sigma_k} \ln \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \Sigma_k) \\&= \sum_i z_{ik} \frac{\partial}{\partial \Sigma_k} \left( -\frac{1}{2} \ln |\Sigma_k| - \frac{1}{2} (\mathbf{x}_i - \boldsymbol{\mu}_k)^T \Sigma_k^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_k) \right) \\&= \sum_i z_{ik} \left( -\frac{1}{2} (\Sigma_k^{-1})^T + \frac{1}{2} \Sigma_k^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_k) (\mathbf{x}_i - \boldsymbol{\mu}_k)^T \Sigma_k^{-1} \right) \\&= \frac{1}{2} \sum_i z_{ik} \left( -\Sigma_k^{-1} + \Sigma_k^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_k) (\mathbf{x}_i - \boldsymbol{\mu}_k)^T \Sigma_k^{-1} \right) \quad (15) \\&= 0\end{aligned}$$

となる

# 混合ガウス分布の再解釈

- ここで、以下の微分公式を用いた

$$\frac{\partial}{\partial \mathbf{X}} \ln |\mathbf{X}| = (\mathbf{X}^{-1})^T \quad (16)$$

- これより

$$\sum_i z_{ik} \boldsymbol{\Sigma}_k^{-1} = \sum_i z_{ik} \boldsymbol{\Sigma}_k^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_k)(\mathbf{x}_i - \boldsymbol{\mu}_k)^T \boldsymbol{\Sigma}_k^{-1} \quad (17)$$

であるから、両辺に左右から  $\boldsymbol{\Sigma}_k$  を掛けて

$$\begin{aligned} \sum_i z_{ik} \boldsymbol{\Sigma}_k &= \sum_i z_{ik} (\mathbf{x}_i - \boldsymbol{\mu}_k)(\mathbf{x}_i - \boldsymbol{\mu}_k)^T \\ \boldsymbol{\Sigma}_k \sum_i z_{ik} &= \sum_i z_{ik} (\mathbf{x}_i - \boldsymbol{\mu}_k)(\mathbf{x}_i - \boldsymbol{\mu}_k)^T \\ \boldsymbol{\Sigma}_k &= \frac{1}{\sum_i z_{ik}} \sum_i z_{ik} (\mathbf{x}_i - \boldsymbol{\mu}_k)(\mathbf{x}_i - \boldsymbol{\mu}_k)^T \end{aligned} \quad (18)$$

のようになる

# 混合ガウス分布の再解釈

- 上式をみても、やはり、完全データ  $\{X, Z\}$  について、 $\Sigma_k$  は陽な形で求まっていることが分かる

# 混合ガウス分布の再解釈

- $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  の  $\pi_k$  に関する最大化
  - $\sum_k \pi_k = 1$  という制約条件を考慮し、ラグランジュの未定乗数法で解く
  - 従って、以下の量を最大化する

$$\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta}) + \lambda \left( \sum_k \pi_k - 1 \right) \quad (19)$$

- $\pi_k$  について微分して 0 とおくと、次のようになる

$$\begin{aligned} & \frac{\partial}{\partial \pi_k} \left( \ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta}) + \lambda \left( \sum_k \pi_k - 1 \right) \right) \\ &= \frac{\partial}{\partial \pi_k} \left( \sum_i \sum_k z_{ik} (\ln \pi_k + \ln \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)) + \lambda \left( \sum_k \pi_k - 1 \right) \right) \\ &= \sum_i z_{ik} \frac{\partial}{\partial \pi_k} \ln \pi_k + \lambda \end{aligned}$$

# 混合ガウス分布の再解釈

$$= \sum_i z_{ik} \frac{1}{\pi_k} + \lambda = 0 \quad (20)$$

- これより、両辺に  $\pi_k$  を掛けて

$$\sum_i z_{ik} + \lambda \pi_k = 0 \quad (21)$$

全ての  $k$  について総和を取ると

$$\begin{aligned} \sum_k \sum_i z_{ik} + \sum_k \lambda \pi_k &= 0 \\ \sum_i \left( \sum_k z_{ik} \right) + \lambda \sum_k \pi_k &= 0 \\ \sum_i 1 + \lambda &= 0 \\ N + \lambda &= 0 \\ \therefore \lambda &= -N \end{aligned} \quad (22)$$



# 混合ガウス分布の再解釈

- よって

$$\begin{aligned}\sum_i z_{ik} \frac{1}{\pi_k} - N &= 0 \\ \sum_i z_{ik} - N\pi_k &= 0 \\ N\pi_k &= \sum_i z_{ik} \\ \therefore \pi_k &= \frac{1}{N} \sum_i z_{ik}\end{aligned}\tag{23}$$

- $\pi_k$  も、完全データ (特に潜在変数) が与えられていれば、陽な形で求める
- EM アルゴリズムにおける  $\mu_k, \Sigma_k, \pi_k$  の更新式は、ここで求めた式の  $z_{ik}$  を、負担率  $\gamma(z_{ik})$  にそのまま置き換えたものである

# 混合ガウス分布の再解釈

- 事後確率分布  $p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})$  に関する期待値の計算
  - 完全データ対数尤度関数  $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  の最大化は、陽な形で解けた
  - これらの全ての式には  $z_{ik}$  が登場したが、実際には潜在変数は分からないので、 $z_{ik}$  を何かで代用しなければならない
- 結局、完全データ対数尤度関数  $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  の、事後確率分布  $p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})$  に関する期待値を考えるしかない

# 混合ガウス分布の再解釈

- 事後確率分布は次のように書ける

$$\begin{aligned} & p(z_i | x_i, \theta) \\ = & \frac{p(x_i | z_i, \theta) p(z_i | \theta)}{p(x_i | \theta)} \end{aligned} \quad (24)$$

$$\propto p(x_i | z_i, \theta) p(z_i | \theta) \quad (25)$$

( $\because p(x_i | \theta)$  は、 $z_i$  には依存しない定数項)

$$\begin{aligned} & = \left( \prod_k \mathcal{N}(x_i | \mu_k, \Sigma_k)^{z_{ik}} \right) \left( \prod_k \pi_k^{z_{ik}} \right) \\ & = \prod_k (\pi_k \mathcal{N}(x_i | \mu_k, \Sigma_k))^{z_{ik}} \end{aligned} \quad (26)$$

以上より

$$p(z_i | x_i, \theta) \propto \prod_k (\pi_k \mathcal{N}(x_i | \mu_k, \Sigma_k))^{z_{ik}} \quad (27)$$

# 混合ガウス分布の再解釈

であるので、 $p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})$  は

$$p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}) \propto \prod_i \prod_k (\pi_k \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k))^{z_{ik}} \quad (28)$$

- $p(z_i | \mathbf{x}_i, \boldsymbol{\theta})$  を等式で表すためには、 $z_i$  で総和を取って 1 になる (確率としての条件を満たす) ように、**正規化すればよい**

$$p(z_i | \mathbf{x}_i, \boldsymbol{\theta}) = \frac{\prod_k (\pi_k \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k))^{z_{ik}}}{\sum_{\mathbf{z}_i} \prod_k (\pi_k \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k))^{z_{ik}}} \quad (29)$$

# 混合ガウス分布の再解釈

- まず、事後確率  $p(z_i | x_i, \theta)$  に関する、 $z_{ik}$  の期待値を求めてみる

$$\begin{aligned} & \mathbb{E}_{z_i \sim p(z_i | x_i, \theta)} [z_{ik}] \\ &= \sum_{z_i} z_{ik} p(z_i | x_i, \theta) \\ &= \sum_{z_i} z_{ik} \frac{\prod_k (\pi_k \mathcal{N}(x_i | \mu_k, \Sigma_k))^{z_{ik}}}{\sum_{z_i} \prod_k (\pi_k \mathcal{N}(x_i | \mu_k, \Sigma_k))^{z_{ik}}} \end{aligned} \quad (30)$$

- ここで

$$\sum_{z_i} \prod_k (\pi_k \mathcal{N}(x_i | \mu_k, \Sigma_k))^{z_{ik}} = \sum_k (\pi_k \mathcal{N}(x_i | \mu_k, \Sigma_k)) \quad (31)$$

と書けることに注意する

- $z_i$  は、1-of-K 符号化法で表現されている

# 混合ガウス分布の再解釈

- $\prod_k (\pi_k \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k))^{z_{ik}}$  は、 $z_{ik} = 1$  の場合、 $j \neq k$  に対して  $z_{ij} = 0$  であるから、 $\pi_k \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$  という単一の項として書ける
- 全ての  $z_i$  についての総和は、 $z_i$  の中で、要素が 1 になるインデックス  $k$  についての総和を意味する

- また

$$\sum_{z_i} z_{ik} \prod_k (\pi_k \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k))^{z_{ik}} = \pi_k \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \quad (32)$$

であることにも注意する

- $\sum_{z_i}$  の総和の中身は、 $z_i$  が  $z_{ik} = 1$  となるとき以外は、0 である (総和の中に  $z_{ik}$  があるため)
- 従って、 $z_i$  が  $z_{ik} = 1$  となるときの項  $\prod_k (\pi_k \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k))^{z_{ik}}$ 、即ち  $\pi_k \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$  だけが出現する

# 混合ガウス分布の再解釈

- これより

$$\begin{aligned} & \mathbb{E}_{\mathbf{z}_i \sim p(\mathbf{z}_i | \mathbf{x}_i, \boldsymbol{\theta})} [z_{ik}] \\ &= \frac{\sum_{\mathbf{z}_i} z_{ik} \prod_k (\pi_k \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k))^{z_{ik}}}{\sum_{\mathbf{z}_i} \prod_k (\pi_k \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k))^{z_{ik}}} \\ &= \frac{\pi_k \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_k \pi_k \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)} \equiv \gamma(z_{ik}) \end{aligned} \quad (33)$$

であるから、データ点  $\mathbf{x}_i$  に対する、 $k$  番目のガウス要素の負担率に一致

# 混合ガウス分布の再解釈

- これより、事後確率  $p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})$  に関する、完全データ対数尤度関数  $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  の期待値は

$$\begin{aligned} & \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})} [\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})] \\ &= \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})} \left[ \sum_i \sum_k z_{ik} (\ln \pi_k + \ln \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)) \right] \\ &= \sum_i \sum_k \mathbb{E}_{\mathbf{z}_i \sim p(\mathbf{z}_i|\mathbf{x}_i, \boldsymbol{\theta})} [z_{ik} (\ln \pi_k + \ln \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k))] \quad (34) \end{aligned}$$

$$= \sum_i \sum_k \mathbb{E}_{\mathbf{z}_i \sim p(\mathbf{z}_i|\mathbf{x}_i, \boldsymbol{\theta})} [z_{ik}] (\ln \pi_k + \ln \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)) \quad (35)$$

$$= \sum_i \sum_k \gamma(z_{ik}) (\ln \pi_k + \ln \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)) \quad (36)$$

である



# 混合ガウス分布の再解釈

- これは  $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  において、 $z_{ik}$  を  $\gamma(z_{ik})$  に置き換えたものと等しい

$$\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta}) = \sum_i \sum_k z_{ik} (\ln \pi_k + \ln \mathcal{N}(\mathbf{x}_i|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)) \quad (37)$$

- 先ほどは、 $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  を最大化するような、パラメータ  $\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k, \pi_k$  の式を導出した
- これらの式について、 $z_{ik}$  を  $\gamma(z_{ik})$  に置き換えれば、そのまま期待値を最大化する式として使える
- $\gamma(z_{ik})$  に置き換えた式は、EM アルゴリズムにおける更新式と一致

# 混合ガウス分布の再解釈

- ここまでの話の流れ

- 1 対数尤度関数  $\ln p(\mathbf{X}|\boldsymbol{\theta})$  の最大化よりも、完全データ対数尤度関数  $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  の最大化の方が簡単であると仮定した
- 2 この仮定は、混合ガウス分布の場合について成り立っていた
- 3  $\ln p(\mathbf{X}|\boldsymbol{\theta})$  の代わりに、 $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  の最大化を考えた
- 4 しかし  $\mathbf{Z}$  に関する情報がないので、代わりに、事後確率分布  $p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})$  による、 $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  の期待値を最大化しようとするのが、EM アルゴリズムであった
- 5 混合ガウス分布の場合について実際に試すと、期待値の最大化によって、パラメータの更新式が再び導出できた

# 混合ガウス分布の再解釈

- これからの話の流れ
  - K-Means 法と、混合ガウス分布に対する EM アルゴリズムを比較する

## 1 EM アルゴリズム

- EM アルゴリズムの解釈
- 混合ガウス分布の再解釈
- K-Means 法との関連
- 一般の EM アルゴリズム
- MAP 推定に対する EM アルゴリズム
- EM アルゴリズムの拡張
- EM アルゴリズムに関する補足
- 逐次型の EM アルゴリズム

- K-Means 法と、混合ガウス分布に対する EM アルゴリズムの関係
  - K-Means 法では、各データ点は、ただ一つのクラスタに割り当てられる (ハード割り当て)
  - EM アルゴリズムでは、事後確率  $\gamma(z_{ik}) \equiv p(z_k = 1 | \mathbf{x}_i)$  に基づいて、各データをソフトに割り当てる (ソフト割り当て)
- K-Means 法は、混合ガウス分布に対する EM アルゴリズムの、ある極限として得られる

## ● K-Means 法の導出

- 次のように、各ガウス分布の共分散行列が  $\epsilon \mathbf{I}$  で与えられる、混合ガウスモデル  $p(\mathbf{x}|\boldsymbol{\theta})$  を考える ( $\epsilon$  は定数とする)

$$\begin{aligned} & p(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \\ &= p(\mathbf{x}|\boldsymbol{\mu}_k, \epsilon \mathbf{I}) \\ &= \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \epsilon \mathbf{I}) \\ &= \frac{1}{(2\pi)^{\frac{D}{2}}} \frac{1}{|\epsilon \mathbf{I}|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_k)^T (\epsilon \mathbf{I})^{-1} (\mathbf{x} - \boldsymbol{\mu}_k) \right\} \quad (38) \end{aligned}$$

$$= \frac{1}{(2\pi\epsilon)^{\frac{D}{2}}} \exp \left\{ -\frac{1}{2\epsilon}(\mathbf{x} - \boldsymbol{\mu}_k)^T (\mathbf{x} - \boldsymbol{\mu}_k) \right\} \quad (39)$$

$$\begin{aligned} & (\because |\epsilon \mathbf{I}|^{\frac{1}{2}} = (\epsilon^D |\mathbf{I}|)^{\frac{1}{2}} = (\epsilon^D)^{\frac{1}{2}} = \epsilon^{\frac{D}{2}}) \\ &= \frac{1}{(2\pi\epsilon)^{\frac{D}{2}}} \exp \left\{ -\frac{1}{2\epsilon} \|\mathbf{x} - \boldsymbol{\mu}_k\|^2 \right\} \quad (40) \end{aligned}$$

$$p(\mathbf{x}|\boldsymbol{\theta}) = \sum_k \pi_k p(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \quad (41)$$

$$= \sum_k \pi_k \frac{1}{(2\pi\epsilon)^{\frac{D}{2}}} \exp \left\{ -\frac{1}{2\epsilon} \|\mathbf{x} - \boldsymbol{\mu}_k\|^2 \right\} \quad (42)$$

- この混合ガウスモデルについて、EM アルゴリズムを実行する
- 最初に、データ点  $\mathbf{x}_i$  に対する、 $k$  番目のガウス要素の負担率  $\gamma(z_{ik})$  を求めて、 $\epsilon \rightarrow 0$  についての極限を取ってみる

$$\begin{aligned} \gamma(z_{ik}) &= \frac{\pi_k \mathcal{N}(\mathbf{x}_i|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_j \pi_j \mathcal{N}(\mathbf{x}_i|\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} \\ &= \frac{\pi_k \exp \left\{ -\frac{1}{2\epsilon} \|\mathbf{x} - \boldsymbol{\mu}_k\|^2 \right\}}{\sum_j \pi_j \exp \left\{ -\frac{1}{2\epsilon} \|\mathbf{x} - \boldsymbol{\mu}_j\|^2 \right\}} \end{aligned} \quad (43)$$

- 負担率は、以下のように変形できる

$$\begin{aligned} & \frac{\pi_k \exp \left\{ -\frac{1}{2\epsilon} \|\mathbf{x} - \boldsymbol{\mu}_k\|^2 \right\}}{\sum_j \pi_j \exp \left\{ -\frac{1}{2\epsilon} \|\mathbf{x} - \boldsymbol{\mu}_j\|^2 \right\}} \\ &= \left( \frac{\sum_j \pi_j \exp \left\{ -\frac{1}{2\epsilon} \|\mathbf{x} - \boldsymbol{\mu}_j\|^2 \right\}}{\pi_k \exp \left\{ -\frac{1}{2\epsilon} \|\mathbf{x} - \boldsymbol{\mu}_k\|^2 \right\}} \right)^{-1} \\ &= \left( \sum_j \frac{\pi_j}{\pi_k} \frac{(\exp \left\{ -\|\mathbf{x} - \boldsymbol{\mu}_j\|^2 \right\})^{\frac{1}{2\epsilon}}}{(\exp \left\{ -\|\mathbf{x} - \boldsymbol{\mu}_k\|^2 \right\})^{\frac{1}{2\epsilon}}} \right)^{-1} \\ &= \left( \sum_j \frac{\pi_j}{\pi_k} \left( \frac{\exp \left\{ -\|\mathbf{x} - \boldsymbol{\mu}_j\|^2 \right\}}{\exp \left\{ -\|\mathbf{x} - \boldsymbol{\mu}_k\|^2 \right\}} \right)^{\frac{1}{2\epsilon}} \right)^{-1} \\ &= \left( 1 + \sum_{j \neq k} \frac{\pi_j}{\pi_k} \left( \frac{\exp \left\{ -\|\mathbf{x} - \boldsymbol{\mu}_j\|^2 \right\}}{\exp \left\{ -\|\mathbf{x} - \boldsymbol{\mu}_k\|^2 \right\}} \right)^{\frac{1}{2\epsilon}} \right)^{-1} \end{aligned} \quad (44)$$



- ここで、 $k^*$  を次で定める

$$k^* = \arg \min_j \|\mathbf{x} - \boldsymbol{\mu}_j\|^2 = \arg \max_j (-\|\mathbf{x} - \boldsymbol{\mu}_j\|^2) \quad (45)$$

$k = k^*$  であるとき、以下の、 $\epsilon \rightarrow 0$  による極限

$$\lim_{\epsilon \rightarrow 0} \left( \sum_{j \neq k} \frac{\pi_j}{\pi_k} \left( \frac{\exp \{-\|\mathbf{x} - \boldsymbol{\mu}_j\|^2\}}{\exp \{-\|\mathbf{x} - \boldsymbol{\mu}_k\|^2\}} \right)^{\frac{1}{2\epsilon}} \right) \quad (46)$$

を考えると、全ての  $j \neq k^*$  について

$$\frac{\exp \{-\|\mathbf{x} - \boldsymbol{\mu}_j\|^2\}}{\exp \{-\|\mathbf{x} - \boldsymbol{\mu}_k\|^2\}} < 1 \quad (47)$$

が成立するので

$$\lim_{\epsilon \rightarrow 0} \left( \sum_{j \neq k} \frac{\pi_j}{\pi_k} \left( \frac{\exp \{ -\|\mathbf{x} - \boldsymbol{\mu}_j\|^2 \}}{\exp \{ -\|\mathbf{x} - \boldsymbol{\mu}_k\|^2 \}} \right)^{\frac{1}{2\epsilon}} \right) = 0 \quad (48)$$

である

- 従って、 $k = k^*$  のとき

$$\begin{aligned} & \lim_{\epsilon \rightarrow 0} \gamma(z_{ik}) \\ &= \lim_{\epsilon \rightarrow 0} \frac{\pi_k \exp \left\{ -\frac{1}{2\epsilon} \|\mathbf{x} - \boldsymbol{\mu}_k\|^2 \right\}}{\sum_j \pi_j \exp \left\{ -\frac{1}{2\epsilon} \|\mathbf{x} - \boldsymbol{\mu}_j\|^2 \right\}} \\ &= \lim_{\epsilon \rightarrow 0} \left( 1 + \sum_{j \neq k} \frac{\pi_j}{\pi_k} \left( \frac{\exp \{ -\|\mathbf{x} - \boldsymbol{\mu}_j\|^2 \}}{\exp \{ -\|\mathbf{x} - \boldsymbol{\mu}_k\|^2 \}} \right)^{\frac{1}{2\epsilon}} \right)^{-1} \end{aligned}$$

$$= (1 + 0)^{-1} = 1 \quad (49)$$

から、 $\gamma(z_{ik}) \rightarrow 1$  ( $\epsilon \rightarrow 0$ ) がいえる

- $k \neq k^*$  のとき

$$1 = \sum_k \gamma(z_{ik}) = \gamma(z_{ik^*}) + \sum_{k \neq k^*} \gamma(z_{ik}) \quad (50)$$

であって、両辺の  $\epsilon \rightarrow 0$  による極限を取れば

$$\begin{aligned} 1 &= \lim_{\epsilon \rightarrow 0} \left( \gamma(z_{ik^*}) + \sum_{k \neq k^*} \gamma(z_{ik}) \right) \\ \Rightarrow 1 &= \lim_{\epsilon \rightarrow 0} \gamma(z_{ik^*}) + \lim_{\epsilon \rightarrow 0} \sum_{k \neq k^*} \gamma(z_{ik}) \\ \Rightarrow 1 &= 1 + \lim_{\epsilon \rightarrow 0} \sum_{k \neq k^*} \gamma(z_{ik}) \end{aligned} \quad (51)$$

となるから

$$\lim_{\epsilon \rightarrow 0} \sum_{k \neq k^*} \gamma(z_{ik}) = 0 \quad (52)$$

が明らかに成立するほか、以下の不等式が

$$0 \leq \gamma(z_{ik}) \leq \sum_{k \neq k^*} \gamma(z_{ik}) \quad (53)$$

$\gamma(z_{ik}) \geq 0$  ゆえ成立するので ( $\gamma(z_{ik})$  は確率値)、両辺の  $\epsilon \rightarrow 0$  による極限を再び取れば

$$0 \leq \lim_{\epsilon \rightarrow 0} \gamma(z_{ik}) \leq \lim_{\epsilon \rightarrow 0} \sum_{k \neq k^*} \gamma(z_{ik}) = 0 \quad (54)$$

従って、 $k \neq k^*$  の場合は

$$\lim_{\epsilon \rightarrow 0} \gamma(z_{ik}) = 0 \quad (55)$$

である

# K-Means 法との関連

- これより、データ点  $x_i$  に関する負担率  $\gamma(z_{ik})$  は、1 に収束する  $k^*$  番目の負担率  $\gamma(z_{ik^*})$  を除き、全て 0 に収束する

$$\gamma(z_{ik}) \equiv p(z_{ik} = 1 | x_i) = \begin{cases} 1 & (k = k^* \text{ の場合}) \\ 0 & (\text{それ以外の場合}) \end{cases} \quad (56)$$

- これは、 $k^*$  番目のクラスタに**確率 1 で属する**ということ、即ち、クラスタ  $k^*$  への**ハード割り当て**を意味する
- $k^* = \arg \min_j \|x - \mu_j\|^2$  であるから、結局、各データ点は、**平均ベクトル  $\mu$  への二乗ユークリッド距離が最小となるクラスタ**に割り当てることになる

# K-Means 法との関連

- $\gamma(z_{ik})$  を  $r_{ik}$  に置き換えれば、EM アルゴリズムにおける  $\mu_k$  の更新式は、K-Means における平均ベクトルの更新式に帰着

$$\text{K-Means :} \quad \mu_k = \frac{1}{\sum_i r_{ik}} \sum_i r_{ik} \mathbf{x}_i \quad (57)$$

$$\text{EM アルゴリズム :} \quad \mu_k = \frac{1}{\sum_i \gamma(z_{ik})} \sum_i \gamma(z_{ik}) \mathbf{x}_i \quad (58)$$

- 従って、混合ガウスモデルの EM アルゴリズムにおいて、各ガウス分布の共分散行列を  $\epsilon \mathbf{I}$  としたとき、 $\epsilon \rightarrow 0$  の極限を取ると、K-Means 法が得られる

- 期待完全データ対数尤度の計算

- $\mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})} [\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})]$  を計算する
- 完全データ対数尤度関数  $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  の、事後確率  $p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})$  による期待値
- 次のように計算する

$$\begin{aligned} & \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})} [\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})] \\ &= \sum_i \sum_k \gamma(z_{ik}) (\ln \pi_k + \ln \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)) \\ &= \sum_i \sum_k \gamma(z_{ik}) (\ln \pi_k + \ln \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \epsilon \mathbf{I})) \\ &= \sum_i \sum_k \gamma(z_{ik}) \left( \ln \pi_k + \ln \left( \frac{1}{(2\pi\epsilon)^{\frac{D}{2}}} \exp \left\{ -\frac{1}{2\epsilon} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2 \right\} \right) \right) \\ &= \sum_i \sum_k \gamma(z_{ik}) \left( \ln \pi_k - \frac{D}{2} \ln(2\pi\epsilon) - \frac{1}{2\epsilon} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2 \right) \quad (59) \end{aligned}$$

- 両辺に  $\epsilon$  を掛けると

$$\begin{aligned} & \epsilon \cdot \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})} [\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})] \\ &= \sum_i \sum_k \gamma(z_{ik}) \left( \epsilon \ln \pi_k - \right. \\ & \quad \left. \frac{D}{2} \epsilon \ln(2\pi\epsilon) - \frac{1}{2} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2 \right) \end{aligned} \quad (60)$$

- $\epsilon \rightarrow 0$  の極限を取ると

$$\gamma(z_{ik}) \rightarrow r_{ik}, \quad \epsilon \ln \pi_k \rightarrow 0, \quad \epsilon \ln(2\pi\epsilon) \rightarrow 0 \quad (61)$$

であるから

$$\begin{aligned} & \lim_{\epsilon \rightarrow 0} \epsilon \cdot \mathbb{E}_{\mathbf{Z} \sim p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})} [\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})] \\ &= \sum_i \sum_k r_{ik} \left( -\frac{1}{2} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2 \right) \end{aligned}$$



# K-Means 法との関連

$$= -\frac{1}{2} \sum_i \sum_k r_{ik} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2 \quad (62)$$

$$= -J \quad (63)$$

- よって、期待完全データ対数尤度  $\mathbb{E}_{\mathbf{Z}} [\ln p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\theta})]$  の最大化は、  
K-Means における目的関数  $J$  の最小化と同等である

# K-Means 法との関連

- その他のパラメータ

- K-Means 法では、各クラスタの分散は推定しない
- 実際に、混合ガウスモデルにおいて、各クラスタの共分散行列は  $\epsilon I$  で固定した

- 混合ガウスモデルの混合係数  $\pi_k$  の更新式は、次のようであった

$$\pi_k = \frac{\sum_i \gamma(z_{ik})}{N} \quad (64)$$

$\epsilon \rightarrow 0$  の極限においては、 $\gamma(z_{ik}) \rightarrow r_{ik}$  であるから

$$\pi_k = \frac{\sum_i r_{ik}}{N} = \frac{N_k}{N} \quad (65)$$

- これは、 $\pi_k$  の値を、 $k$  番目のクラスタに割り当てられる、データ数の割合に設定することを意味している
- $\pi_k$  の値は K-Means 法においては、もはや何の意味も持たない

# K-Means 法との関連

- ここまでの話の流れ

- K-Means 法は、混合ガウス分布に対する EM アルゴリズムの、ある極限として得られることが分かった

- これからの話の流れ

- $\ln p(\mathbf{X}|\boldsymbol{\theta})$  の代わりに、 $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  を最大化してもよい根拠を明らかにする
- $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  の、 $p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})$  による期待値を取る理由を明らかにする
- E ステップと M ステップが、確かに対数尤度関数  $\ln p(\mathbf{X}|\boldsymbol{\theta})$  を増加させることを証明する
- これらの解明のために、一般的な EM アルゴリズムの取り扱いについて調べる

## 1 EM アルゴリズム

- EM アルゴリズムの解釈
- 混合ガウス分布の再解釈
- K-Means 法との関連
- 一般の EM アルゴリズム
- MAP 推定に対する EM アルゴリズム
- EM アルゴリズムの拡張
- EM アルゴリズムに関する補足
- 逐次型の EM アルゴリズム

# 一般の EM アルゴリズム

- EM アルゴリズムの目的 (再掲)
  - 潜在変数をもつ確率モデルについて、パラメータの最尤解を求める
- 一般的な EM アルゴリズムの取り扱い
  - これまでは、混合ガウスモデルに対して、EM アルゴリズムを発見的に導いた
  - ここでは、EM アルゴリズムが、確かに尤度関数  $\ln p(\mathbf{X}|\boldsymbol{\theta})$  を極大化することを証明する
  - 後述する変分推論の基礎をなす部分
- 尤度関数  $p(\mathbf{X}|\boldsymbol{\theta})$  の記述
  - 全ての観測変数と、潜在変数をそれぞれ  $\mathbf{X}, \mathbf{Z}$  と表す
  - 確率モデルの全てのパラメータの組を、 $\boldsymbol{\theta}$  と表す

# 一般の EM アルゴリズム

- 同時確率分布を  $p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  とすると、尤度関数は次のようになる

$$p(\mathbf{X}|\boldsymbol{\theta}) = \sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta}) \quad (66)$$

- 連続潜在変数の場合は、次のように、総和を積分に置き換えればよい

$$p(\mathbf{X}|\boldsymbol{\theta}) = \int_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta}) d\mathbf{Z} \quad (67)$$

- ここでは、連続潜在変数の場合を考える
- 重要な仮定**
  - $\ln p(\mathbf{X}|\boldsymbol{\theta})$  の最大化よりも、完全データ対数尤度関数  $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  の最大化の方が、容易である
  - 以前に見た尤度関数  $\ln p(\mathbf{X}|\boldsymbol{\theta})$  では、対数の中に総和が含まれており (**log-sum**)、複雑な形をしていた

# 一般の EM アルゴリズム

- $Z$  についての情報を加えることで、尤度関数から log-sum の構造を消すことができた
- 対数  $\ln$  がガウス分布に直接作用するようになったため、尤度関数の形が簡単になった

- EM アルゴリズムで行うこと

- $\ln p(\mathbf{X}|\boldsymbol{\theta})$  ではなく  $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  を最適化しようとしたが、 $Z$  に関する情報がないので、それはできない
- そこで、事後確率  $p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})$  による、 $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  の期待値  $\mathbb{E}_Z [\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})]$  を最大化する
- これ以降の議論のために、**イェンセンの不等式**、**エントロピー**、**KL ダイバージェンス**について確認しておく

# 一般の EM アルゴリズム

- イェンセンの不等式

- 凸関数  $f(x)$  は、任意の点集合  $\{x_i\}$  について以下を満たす

$$f\left(\sum_i \lambda_i x_i\right) \leq \sum_i \lambda_i f(x_i) \quad (68)$$

- ここで、 $\lambda_i \geq 0$ ,  $\sum_i \lambda_i = 1$  であるとする
- $\lambda_i$  を、値  $\{x_i\}$  を取る離散確率変数  $x$  上の確率分布  $p(x)$  と解釈すると

$$\begin{aligned} f\left(\sum_i p(x_i) x_i\right) &\leq \sum_i p(x_i) f(x_i) \\ f(\mathbb{E}[x]) &\leq \mathbb{E}[f(x)] \end{aligned} \quad (69)$$



# 一般の EM アルゴリズム

- $x$  が連続変数であれば、イェンセンの不等式は次のように書ける

$$f\left(\int \boldsymbol{x} p(\boldsymbol{x}) d\boldsymbol{x}\right) \leq \int f(\boldsymbol{x}) p(\boldsymbol{x}) d\boldsymbol{x} \quad (70)$$

例えば、 $f(x) = -\ln x$  は凸関数であるから

$$-\ln\left(\int \boldsymbol{x} p(\boldsymbol{x}) d\boldsymbol{x}\right) \leq \int (-\ln \boldsymbol{x}) p(\boldsymbol{x}) d\boldsymbol{x} \quad (71)$$

よって

$$\ln\left(\int \boldsymbol{x} p(\boldsymbol{x}) d\boldsymbol{x}\right) \geq \int (\ln \boldsymbol{x}) p(\boldsymbol{x}) d\boldsymbol{x} \quad (72)$$

# 一般の EM アルゴリズム

- エントロピー

- 確率分布  $p(\boldsymbol{x})$  について、エントロピーは以下で定義される

$$H[p] = - \int p(\boldsymbol{x}) \ln p(\boldsymbol{x}) d\boldsymbol{x} \quad (73)$$

- エントロピーは、確率分布  $p(\boldsymbol{x})$  を入力として、上記の量を返す、**汎関数** (Functional) である
- 汎関数とは、入力として関数を取り、出力として汎関数の値を返すものである

## ● KL ダイバージェンス

- 確率分布  $p(\mathbf{x})$  と  $q(\mathbf{x})$  の間の、カルバック-ライブラーダイバージェンスを、 $\text{KL}(p||q)$  と表す
- 確率分布  $p(\mathbf{x})$  と  $q(\mathbf{x})$  の間の、(擬似的な) 距離を表す指標である

$$\text{KL}(p||q) = - \int p(\mathbf{x}) \ln \left\{ \frac{q(\mathbf{x})}{p(\mathbf{x})} \right\} d\mathbf{x} \quad (74)$$

- $\text{KL}(p||q) \geq 0$  であり、等号成立は  $p(\mathbf{x}) = q(\mathbf{x})$  のときに限る
- 2つの分布が完全に同一であれば、KL ダイバージェンスは 0 で最小値を取る
- また厳密には距離ではないため、対称性は成立しない
- 従って、一般に  $\text{KL}(p||q) \neq \text{KL}(q||p)$  となる

# 一般の EM アルゴリズム

- $\ln p(\mathbf{X}|\boldsymbol{\theta})$  の分解

- EM アルゴリズムについて考察するために、まずは  $\ln p(\mathbf{X}|\boldsymbol{\theta})$  を分解してみよう
- 潜在変数についての分布を  $q(\mathbf{Z})$  とおく
- $q(\mathbf{Z})$  の設定の仕方によらず、 $\ln p(\mathbf{X}|\boldsymbol{\theta})$  を次のように分解できる

$$\ln p(\mathbf{X}|\boldsymbol{\theta}) = \mathcal{L}(q, \boldsymbol{\theta}) + \text{KL}(q||p) \quad (75)$$

- $\mathcal{L}(q, \boldsymbol{\theta})$  は、分布  $q(\mathbf{Z})$  の汎関数であり、かつパラメータ  $\boldsymbol{\theta}$  の関数である
- $\text{KL}(q||p)$  は、確率分布  $q(\mathbf{Z})$  と  $p(\mathbf{X}|\boldsymbol{\theta})$  の間の、**KL ダイバージェンス**である

# 一般の EM アルゴリズム

- 分解は次のように行える

$$\begin{aligned}\ln p(\mathbf{X}|\boldsymbol{\theta}) &= \underbrace{\left( \sum_{\mathbf{Z}} q(\mathbf{Z}) \right)}_{=1} \ln p(\mathbf{X}|\boldsymbol{\theta}) \\&= \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln p(\mathbf{X}|\boldsymbol{\theta}) \\&= \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \frac{p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})}{p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})} \\&= \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left( \frac{p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})}{q(\mathbf{Z})} \frac{q(\mathbf{Z})}{p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})} \right) \\&= \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \frac{p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})}{q(\mathbf{Z})} - \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \frac{p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})}{q(\mathbf{Z})} \\&= \mathcal{L}(q, \boldsymbol{\theta}) + \text{KL}(q||p)\end{aligned}\tag{76}$$

# 一般の EM アルゴリズム

- ここで  $\mathcal{L}(q, \theta)$  と  $\text{KL}(q||p)$  は以下のように定義した

$$\mathcal{L}(q, \theta) = \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \frac{p(\mathbf{X}, \mathbf{Z} | \theta)}{q(\mathbf{Z})} \quad (77)$$

$$\text{KL}(q||p) = - \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \frac{p(\mathbf{Z} | \mathbf{X}, \theta)}{q(\mathbf{Z})} \quad (78)$$

- $\text{KL}(q||p) \geq 0$  ゆえ、以下の不等式を得る

$$\mathcal{L}(q, \theta) \leq \ln p(\mathbf{X} | \theta) \quad (79)$$

- $\mathcal{L}(q, \theta)$  は、 $q(\mathbf{Z}), \theta$  によらず、常に  $\ln p(\mathbf{X} | \theta)$  の下界をなす
- 下界について確認した後に、EM アルゴリズムの各ステップについて見ていく

# 一般の EM アルゴリズム

**Figure 9.11** Illustration of the decomposition given by (9.70), which holds for any choice of distribution  $q(\mathbf{Z})$ . Because the Kullback-Leibler divergence satisfies  $\text{KL}(q||p) \geq 0$ , we see that the quantity  $\mathcal{L}(q, \theta)$  is a lower bound on the log likelihood function  $\ln p(\mathbf{X}|\theta)$ .




図 1:  $\ln p(\mathbf{X}|\theta)$  の分解

# 下界と上界の定義

- 下界と上界の定義

- 下界と上界は、次のように定義される (実数の集合を  $\mathbb{R}$  とする)

実数  $a \in \mathbb{R}$  が、実数の部分集合  $A \subset \mathbb{R}$  の上界である

$$\Leftrightarrow \text{集合 } A \text{ に属する任意の要素 } x \text{ は、} a \text{ 以下である}$$
$$\Leftrightarrow \forall x \in A, x \leq a \quad (80)$$

実数  $a \in \mathbb{R}$  が、実数の部分集合  $A \subset \mathbb{R}$  の下界である

$$\Leftrightarrow \text{集合 } A \text{ に属する任意の要素 } x \text{ は、} a \text{ 以上である}$$
$$\Leftrightarrow \forall x \in A, a \leq x \quad (81)$$

- 上記の定義は、実数の集合  $\mathbb{R}$  だけでなく、一般の半順序集合について成り立つ
- 例えば、集合  $A$  を  $A = \{x | 0 \leq x\}$  と定義すると、0 以下である実数、例えば  $-1$ 、 $-3$  などは、いずれも集合  $A$  の下界となる



# 一般の EM アルゴリズム

- EM アルゴリズムの概要

- EM アルゴリズムでは、 $\ln p(\mathbf{X}|\boldsymbol{\theta})$  の最尤解を求めるために、**E ステップ**と **M ステップ**の二段階の処理を、交互に繰り返す
- パラメータの現在値を  $\boldsymbol{\theta}^{\text{old}}$  とする

- **E ステップ**

- E ステップでは、下界  $\mathcal{L}(q, \boldsymbol{\theta}^{\text{old}})$  を、 $\boldsymbol{\theta}^{\text{old}}$  を固定しながら、 $q(\mathbf{Z})$  について最大化する
- この問題は、 $\ln p(\mathbf{X}|\boldsymbol{\theta})$  の分解をみれば簡単に解ける

$$\begin{aligned} & \ln p(\mathbf{X}|\boldsymbol{\theta}^{\text{old}}) \\ = & \mathcal{L}(q, \boldsymbol{\theta}^{\text{old}}) + \text{KL}(q||p) \end{aligned} \tag{82}$$

$$\begin{aligned} = & \mathcal{L}(q, \boldsymbol{\theta}^{\text{old}}) + \text{KL}(q(\mathbf{Z})||p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{old}})) \\ & (\text{E ステップ前}) \end{aligned} \tag{83}$$

# 一般の EM アルゴリズム

- 上式において、左辺の  $\ln p(\mathbf{X}|\boldsymbol{\theta}^{\text{old}})$  は、 $q$  には依存しない定数である
- 従って、 $q$  について  $\mathcal{L}(q, \boldsymbol{\theta}^{\text{old}})$  を最大化するためには、 $\text{KL}(q||p)$  を最小化するしかない
- $\text{KL}(q||p)$  を最小化するためには、 $q(\mathbf{Z}) = p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{old}})$  とおいて、 $\text{KL}(q||p) = 0$  とすればよい ( $\text{KL}(q||p) \geq 0$  であるから、最小値は 0)
- このとき、下界  $\mathcal{L}(q, \boldsymbol{\theta}^{\text{old}})$  は、対数尤度  $\ln p(\mathbf{X}|\boldsymbol{\theta}^{\text{old}})$  に一致する

$$\ln p(\mathbf{X}|\boldsymbol{\theta}^{\text{old}}) \tag{84}$$

$$\begin{aligned} &= \mathcal{L}(q, \boldsymbol{\theta}^{\text{old}}) + \text{KL}(q(\mathbf{Z})||p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{old}})) \\ &= \mathcal{L}(q, \boldsymbol{\theta}^{\text{old}}) + \text{KL}(p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{old}})||p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{old}})) \end{aligned} \tag{85}$$

$$\begin{aligned} &= \mathcal{L}(q, \boldsymbol{\theta}^{\text{old}}) \\ &\quad (\text{E ステップ後}) \end{aligned} \tag{86}$$

# 一般の EM アルゴリズム

- 次の図 2 には E ステップの概要が示されている
- $KL(q||p) = 0$  となるように  $q$  を調節している
- 青線（図中の青線）で示されている下界  $\mathcal{L}(q, \theta^{\text{old}})$  が、赤線（図中の赤線）で示されている対数尤度  $\ln p(\mathbf{X}|\theta^{\text{old}})$  のところまで、持ち上げられている

# 一般の EM アルゴリズム

**Figure 9.12** Illustration of the E step of the EM algorithm. The  $q$  distribution is set equal to the posterior distribution for the current parameter values  $\theta^{\text{old}}$ , causing the lower bound to move up to the same value as the log likelihood function, with the KL divergence vanishing.




図 2: EM アルゴリズムの E ステップ

# 一般の EM アルゴリズム

## ● M ステップ

- M ステップでは、下界  $\mathcal{L}(q, \theta)$  を、分布  $q(\mathbf{Z})$  を固定しながら、 $\theta$  について最大化し、新たなパラメータ  $\theta^{\text{new}}$  を得る
- M ステップは下界  $\mathcal{L}$  を増加させるが、 $\text{KL}(q||p) \geq 0$  であるから、対数尤度  $\ln p(\mathbf{X}|\theta)$  も必然的に増加する

$$\begin{aligned} & \ln p(\mathbf{X}|\theta) \\ = & \mathcal{L}(q, \theta) + \text{KL}(q||p) \end{aligned} \tag{87}$$

$$= \mathcal{L}(q, \theta) + \text{KL}(q(\mathbf{Z})||p(\mathbf{Z}|\mathbf{X}, \theta)) \tag{88}$$

$$\begin{aligned} = & \mathcal{L}(q, \theta) + \text{KL}(p(\mathbf{Z}|\mathbf{X}, \theta^{\text{old}})||p(\mathbf{Z}|\mathbf{X}, \theta)) \\ & (\text{M ステップ前}) \end{aligned} \tag{89}$$

- 分布  $q(\mathbf{Z}) = p(\mathbf{Z}|\mathbf{X}, \theta^{\text{old}})$  は、古いパラメータ  $\theta^{\text{old}}$  によって決められており、**M ステップの間は固定**されている

# 一般の EM アルゴリズム

- $KL(q||p)$  は、 $q(\mathbf{Z}) = p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{old}})$  と  $p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})$  との KL ダイバージェンスである
- $q(\mathbf{Z}) = p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{old}})$  と、M ステップ後の新しい事後分布  $p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{new}})$  とは一致しないため、 $KL(q||p) > 0$  となる

$$\begin{aligned} & \ln p(\mathbf{X}|\boldsymbol{\theta}^{\text{new}}) \\ = & \mathcal{L}(q, \boldsymbol{\theta}^{\text{new}}) + KL(p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{old}})||p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{new}})) \quad (90) \\ & \text{(M ステップ後)} \end{aligned}$$

- 対数尤度の増加量は、下界  $\mathcal{L}$  の増加量よりも大きくなる (図 3)

$$\begin{aligned} & \ln p(\mathbf{X}|\boldsymbol{\theta}^{\text{new}}) - \ln p(\mathbf{X}|\boldsymbol{\theta}^{\text{old}}) \\ = & \mathcal{L}(q, \boldsymbol{\theta}^{\text{new}}) + KL(p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{old}})||p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{new}})) - \\ & \mathcal{L}(q, \boldsymbol{\theta}^{\text{old}}) \quad (91) \end{aligned}$$

$$\begin{aligned} = & (\mathcal{L}(q, \boldsymbol{\theta}^{\text{new}}) - \mathcal{L}(q, \boldsymbol{\theta}^{\text{old}})) + \\ & KL(p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{old}})||p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{new}})) \quad (92) \end{aligned}$$

$$\geq \mathcal{L}(q, \boldsymbol{\theta}^{\text{new}}) - \mathcal{L}(q, \boldsymbol{\theta}^{\text{old}}) \quad (93)$$

# 一般の EM アルゴリズム

- 次の図 3 には M ステップの概要が示されている
- 下界  $\mathcal{L}(q, \theta)$  を、 $q(\mathbf{Z})$  を固定しつつ、 $\theta$  について最大化している
- 青の点線で示されている下界  $\mathcal{L}(q, \theta^{\text{old}})$  が、青の実線で示されている下界  $\mathcal{L}(q, \theta^{\text{new}})$  へと、持ち上げられている
- 赤の点線で示される対数尤度  $\ln p(\mathbf{X}|\theta^{\text{old}})$  は、赤の実線で示される対数尤度  $\ln p(\mathbf{X}|\theta^{\text{new}})$  へと、持ち上げられている
- 新たに生じた  $\text{KL}(q||p)$  によって、対数尤度の増加量は、下界  $\mathcal{L}$  の増加量よりも大きくなっている

# 一般の EM アルゴリズム

**Figure 9.13** Illustration of the M step of the EM algorithm. The distribution  $q(\mathbf{Z})$  is held fixed and the lower bound  $\mathcal{L}(q, \theta)$  is maximized with respect to the parameter vector  $\theta$  to give a revised value  $\theta^{\text{new}}$ . Because the KL divergence is nonnegative, this causes the log likelihood  $\ln p(\mathbf{X}|\theta)$  to increase by at least as much as the lower bound does.




図 3: EM アルゴリズムの M ステップ



# 一般の EM アルゴリズム

- M ステップで最大化される量

- M ステップでは下界  $\mathcal{L}(q, \theta)$  を、 $q$  を固定しつつ  $\theta$  について最大化する
- M ステップで最大化するのは、**E ステップ後の下界**  $\mathcal{L}(q, \theta)$  であり、これは次のように表せる ( $q(\mathbf{Z}) = p(\mathbf{X}, \mathbf{Z}|\theta^{\text{old}})$  である)

$$\begin{aligned} & \mathcal{L}(q, \theta) \\ = & \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \frac{p(\mathbf{X}, \mathbf{Z}|\theta)}{q(\mathbf{Z})} \\ = & \sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z}|\theta^{\text{old}}) \ln \frac{p(\mathbf{X}, \mathbf{Z}|\theta)}{p(\mathbf{X}, \mathbf{Z}|\theta^{\text{old}})} \end{aligned} \quad (94)$$

$$\begin{aligned} = & \sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z}|\theta^{\text{old}}) \ln p(\mathbf{X}, \mathbf{Z}|\theta) - \\ & \sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z}|\theta^{\text{old}}) \ln p(\mathbf{X}, \mathbf{Z}|\theta^{\text{old}}) \end{aligned} \quad (95)$$

$$= \mathcal{Q}(\theta, \theta^{\text{old}}) + \text{Const.} \quad (96)$$

# 一般の EM アルゴリズム

- 定数項は、単に分布  $q(\mathbf{Z}) = p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta}^{\text{old}})$  のエントロピーであって、 $\boldsymbol{\theta}$  には依存しないため無視できる
- M ステップで最大化される量は、結局、完全データ対数尤度関数  $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  の、事後確率分布  $p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{old}})$  による期待値  $Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}})$  である
- 最適化しようとしているパラメータ  $\boldsymbol{\theta}$  は、**対数の中にしか現れない**
- 同時分布  $p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  に対して**対数が直接作用**するので、同時分布が例えばガウス分布であれば、対数と指数が打ち消されて、簡単な形になる
- その結果として、不完全データ対数尤度関数  $\ln p(\mathbf{X}|\boldsymbol{\theta})$  の最適化よりも、**非常に単純な手続きとなる**

# 一般の EM アルゴリズム

- E ステップのまとめ

- 下界  $\mathcal{L}(q, \theta^{\text{old}})$  を、 $\theta^{\text{old}}$  を固定しつつ、 $q$  について最大化する
- これは、単に  $q(\mathbf{Z}) = p(\mathbf{Z}|\mathbf{X}, \theta^{\text{old}})$  とすればよい
- 即ち、 $p(\mathbf{Z}|\mathbf{X}, \theta^{\text{old}})$  を計算するだけである

- M ステップのまとめ

- 下界  $\mathcal{L}(q, \theta)$  を、 $q$  を固定しつつ、 $\theta$  について最大化する
- これは、期待値  $\mathcal{Q}(\theta, \theta^{\text{old}})$  を最大化するような、パラメータ  $\theta$  を求めることに相当

- 疑問に対する答え

- $\ln p(\mathbf{X}|\boldsymbol{\theta})$  の代わりに、 $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  を最大化してよい根拠
- そして、 $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  の、 $p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})$  による期待値を取る理由
- 期待値を取る操作は、式の導出の中で、極めて自然に現れた
- 期待値  $Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}})$  の最大化は、 $\mathcal{L}(q, \boldsymbol{\theta})$  の最大化と等価である
- $\mathcal{L}(q, \boldsymbol{\theta})$  は、 $q$  や  $\boldsymbol{\theta}$  によらず、常に  $\ln p(\mathbf{X}|\boldsymbol{\theta})$  の下界である
- 下界を最大化することは、 $\ln p(\mathbf{X}|\boldsymbol{\theta})$  を徐々に大きくしていくことにつながる (図 2 と図 3 を参照)
- これらより、 $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  の期待値を最適化させることは、 $\ln p(\mathbf{X}|\boldsymbol{\theta})$  を最適化させることと等価

# 一般の EM アルゴリズム

- パラメータの更新によって  $\ln p(\mathbf{X}|\boldsymbol{\theta})$  が常に大きくなることの補足
  - 以下のように式変形を行う

$$\begin{aligned} & (\text{M ステップ後の } \ln p(\mathbf{X}|\boldsymbol{\theta})) - (\text{E ステップ後の } \ln p(\mathbf{X}|\boldsymbol{\theta})) \\ &= \ln p(\mathbf{X}|\boldsymbol{\theta}^{\text{new}}) - \ln p(\mathbf{X}|\boldsymbol{\theta}^{\text{old}}) \\ &= \ln \frac{p(\mathbf{X}|\boldsymbol{\theta}^{\text{new}})}{p(\mathbf{X}|\boldsymbol{\theta}^{\text{old}})} \\ &= \underbrace{\sum_{\mathbf{Z}} p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{old}})}_{=1} \ln \frac{p(\mathbf{X}|\boldsymbol{\theta}^{\text{new}})}{p(\mathbf{X}|\boldsymbol{\theta}^{\text{old}})} \\ &= \sum_{\mathbf{Z}} p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{old}}) \ln \frac{p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta}^{\text{new}})}{p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{new}})} \frac{p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{old}})}{p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta}^{\text{old}})} \\ &= \sum_{\mathbf{Z}} p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{old}}) \ln \frac{p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta}^{\text{new}})}{p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta}^{\text{old}})} \frac{p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{old}})}{p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{new}})} \end{aligned}$$

# 一般の EM アルゴリズム

$$\begin{aligned} &= \sum_{\mathbf{Z}} p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{old}}) \ln \frac{p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta}^{\text{new}})}{p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta}^{\text{old}})} + \\ &\quad \sum_{\mathbf{Z}} p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{old}}) \ln \frac{p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{old}})}{p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{new}})} \\ &= \sum_{\mathbf{Z}} p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{old}}) \ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta}^{\text{new}}) - \\ &\quad \sum_{\mathbf{Z}} p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{old}}) \ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta}^{\text{old}}) - \\ &\quad \sum_{\mathbf{Z}} p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{old}}) \ln \frac{p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{old}})}{p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{new}})} \\ &= \mathcal{Q}(\boldsymbol{\theta}^{\text{old}}, \boldsymbol{\theta}^{\text{new}}) - \mathcal{Q}(\boldsymbol{\theta}^{\text{old}}, \boldsymbol{\theta}^{\text{old}}) + \\ &\quad \text{KL} (p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{old}}) || p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}^{\text{new}})) \end{aligned} \tag{97}$$

$$\geq \mathcal{Q}(\boldsymbol{\theta}^{\text{old}}, \boldsymbol{\theta}^{\text{new}}) - \mathcal{Q}(\boldsymbol{\theta}^{\text{old}}, \boldsymbol{\theta}^{\text{old}}) \tag{98}$$

$$\geq 0$$

# 一般の EM アルゴリズム

- 最後の変形は、M ステップでは  $Q(\theta, \theta^{\text{old}})$  を、 $\theta$  について最大化しているから、 $Q(\theta^{\text{old}}, \theta^{\text{new}}) \geq Q(\theta^{\text{old}}, \theta^{\text{old}})$  であることを利用
- 更新によって  $\ln p(\mathbf{X}|\theta)$  は、収束していない限り常に大きくなる

# 一般の EM アルゴリズム

- $\ln p(\mathbf{X}|\boldsymbol{\theta})$  の分解の導出の補足
  - イェンセンの不等式を用いて導出してみよう

$$\begin{aligned}\ln p(\mathbf{X}|\boldsymbol{\theta}) &= \ln \sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta}) \\ &= \ln \sum_{\mathbf{Z}} q(\mathbf{Z}) \frac{p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})}{q(\mathbf{Z})} \\ &\geq \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \frac{p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})}{q(\mathbf{Z})} \\ &= \mathcal{L}(q, \boldsymbol{\theta})\end{aligned}\tag{99}$$

- 不等式の部分でイェンセンの不等式  $\ln(\mathbb{E}[x]) \leq \mathbb{E}[\ln x]$  を用いた



# 一般の EM アルゴリズム

- これより、 $\ln p(\mathbf{X}|\boldsymbol{\theta})$  と  $\mathcal{L}(q, \boldsymbol{\theta})$  の差を調べると

$$\begin{aligned} & \ln p(\mathbf{X}|\boldsymbol{\theta}) - \mathcal{L}(q, \boldsymbol{\theta}) \\ = & \ln p(\mathbf{X}|\boldsymbol{\theta}) - \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \frac{p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})}{q(\mathbf{Z})} \\ = & \underbrace{\sum_{\mathbf{Z}} q(\mathbf{Z}) \ln p(\mathbf{X}|\boldsymbol{\theta})}_{=1} - \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \frac{p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})}{q(\mathbf{Z})} \\ = & \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln p(\mathbf{X}|\boldsymbol{\theta}) - \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \frac{p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})p(\mathbf{X}|\boldsymbol{\theta})}{q(\mathbf{Z})} \\ = & \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln p(\mathbf{X}|\boldsymbol{\theta}) - \\ & \sum_{\mathbf{Z}} q(\mathbf{Z}) (\ln p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}) + \ln p(\mathbf{X}|\boldsymbol{\theta}) - \ln q(\mathbf{Z})) \\ = & - \sum_{\mathbf{Z}} q(\mathbf{Z}) (\ln p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}) - \ln q(\mathbf{Z})) \end{aligned}$$

# 一般の EM アルゴリズム

$$\begin{aligned} &= - \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \frac{p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})}{q(\mathbf{Z})} \\ &= \text{KL}(q||p) \end{aligned} \tag{100}$$

ゆえ、 $\text{KL}(q||p)$  となることが分かったので

$$\ln p(\mathbf{X}|\boldsymbol{\theta}) = \mathcal{L}(q, \boldsymbol{\theta}) + \text{KL}(q||p) \tag{101}$$

のように分解できることが分かる

# 一般の EM アルゴリズム

- パラメータ空間での図示

- EM アルゴリズムは、パラメータ空間でも視覚化できる (図 4)
- **赤の実線**は、最大化したい対象である、不完全データ対数尤度関数  $\ln p(\mathbf{X}|\boldsymbol{\theta})$  を表す

- E ステップ

- パラメータの初期値  $\boldsymbol{\theta}^{\text{old}}$  から始めて、最初の E ステップでは、潜在変数の事後確率分布  $p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})$  を計算
- このとき、**青の実線**で示す下界  $\mathcal{L}(q, \boldsymbol{\theta}^{\text{old}})$  が  $q$  について更新され、下界  $\mathcal{L}$  は、 $\ln p(\mathbf{X}|\boldsymbol{\theta})$  と  $\boldsymbol{\theta}^{\text{old}}$  において一致する
- 下界  $\mathcal{L}$  の曲線は、 $\boldsymbol{\theta}^{\text{old}}$  において  $\ln p(\mathbf{X}|\boldsymbol{\theta})$  と**接する**ことに注意する
- 下界  $\mathcal{L}$  と対数尤度  $\ln p(\mathbf{X}|\boldsymbol{\theta})$  は、 $\boldsymbol{\theta}^{\text{old}}$  において**同じ勾配を持つ**

# 一般の EM アルゴリズム

- M ステップ

- 下界  $\mathcal{L}$  が凹関数で、唯一の最大値をもつとする (例えば混合ガウスモデル)
- M ステップでは、下界  $\mathcal{L}(q, \theta)$  が  $\theta$  について最大化されて、パラメータ  $\theta^{\text{new}}$  が得られる

- 続く E ステップ

- 続く E ステップでは、緑の実線で示した下界  $\mathcal{L}(q, \theta^{\text{new}})$  が計算される
- 下界  $\mathcal{L}(q, \theta^{\text{new}})$  は、 $\ln p(\mathbf{X}|\theta)$  と  $\theta^{\text{new}}$  で接する

# 一般の EM アルゴリズム

- 勾配が等しくなることについての証明
  - 以下の式の、 $\theta$  による微分を考えれば明らか

$$\begin{aligned} & \left. \frac{\partial}{\partial \theta} \ln p(\mathbf{X}|\theta) \right|_{\theta^{\text{old}}} \\ &= \left. \frac{\partial}{\partial \theta} \mathcal{L}(q, \theta) \right|_{\theta^{\text{old}}} + \left. \frac{\partial}{\partial \theta} \text{KL}(q||p) \right|_{\theta^{\text{old}}} \\ &= \left. \frac{\partial}{\partial \theta} \mathcal{L}(q, \theta) \right|_{\theta^{\text{old}}} \end{aligned} \tag{102}$$

- E ステップによって  $\text{KL}(q||p)$  が最小化されるので、 $\theta$  による勾配も当然 0 になるはずである
- このとき、 $\ln p(\mathbf{X}|\theta)$  と  $\mathcal{L}(q, \theta)$  の、 $\theta^{\text{old}}$  における微分値が等しくなる
- 従って、 $\theta^{\text{old}}$  において **両者は接する** ことが分かる
- 直感的には、次のように考えればよい

# 一般の EM アルゴリズム

- 両者が接していなければ、交差しているはずである
- このとき、対数尤度  $\ln p(\mathbf{X}|\boldsymbol{\theta})$  が、下界  $\mathcal{L}$  を上回る ( $\mathcal{L}(q, \boldsymbol{\theta}) > \ln p(\mathbf{X}|\boldsymbol{\theta})$ ) ような  $\boldsymbol{\theta}$  が存在する
- これは、 $\text{KL}(q||p) < 0$  となる可能性があることを示し、従って有り得ないので、両者は接しているはず

# 一般の EM アルゴリズム

**Figure 9.14** The EM algorithm involves alternately computing a lower bound on the log likelihood for the current parameter values and then maximizing this bound to obtain the new parameter values. See the text for a full discussion.




図 4: EM アルゴリズムの手続き

# 一般の EM アルゴリズム

- i.i.d 標本である場合

- データ点  $x_i$  と、対応する潜在変数  $z_i$  が、同一の確率分布  $p(x, z)$  から独立に得られている場合
- 以下のように同時分布  $p(\mathbf{X}, \mathbf{Z})$  を分解できる

$$p(\mathbf{X}, \mathbf{Z}) = \prod_i p(x_i, z_i) \quad (103)$$

- 従って、E ステップで計算される事後確率  $p(\mathbf{Z}|\mathbf{X}, \theta)$  は次のようになる

$$\begin{aligned} p(\mathbf{Z}|\mathbf{X}, \theta) &= \frac{p(\mathbf{X}, \mathbf{Z}|\theta)}{p(\mathbf{X}|\theta)} \\ &= \frac{p(\mathbf{X}, \mathbf{Z}|\theta)}{\sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z}|\theta)} \\ &= \frac{\prod_i p(x_i, z_i|\theta)}{\sum_{\mathbf{Z}} \prod_i p(x_i, z_i|\theta)} \end{aligned}$$



$$\begin{aligned} &= \frac{\prod_i p(\mathbf{x}_i, \mathbf{z}_i | \boldsymbol{\theta})}{\prod_i \sum_{\mathbf{z}} p(\mathbf{x}_i, \mathbf{z}_i | \boldsymbol{\theta})} \\ &= \frac{\prod_i p(\mathbf{x}_i, \mathbf{z}_i | \boldsymbol{\theta})}{\prod_i p(\mathbf{x}_i | \boldsymbol{\theta})} \\ &= \prod_i \frac{p(\mathbf{x}_i, \mathbf{z}_i | \boldsymbol{\theta})}{p(\mathbf{x}_i | \boldsymbol{\theta})} \\ &= \prod_i p(\mathbf{z}_i | \mathbf{x}_i, \boldsymbol{\theta}) \end{aligned} \tag{104}$$

各データ点に対する事後確率  $p(\mathbf{z}_i | \mathbf{x}_i, \boldsymbol{\theta})$  の積として、 $p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta})$  を表現できた

- 例えば混合ガウスモデルであれば、データ点  $\mathbf{x}_i$  に対する各ガウス分布の負担率は、データ  $\mathbf{x}_i$  とガウス分布のパラメータ  $\boldsymbol{\theta}$  にのみ依存し、他のデータ点には依存しないことを示している

# 一般の EM アルゴリズム

- ここまでの話の流れ

- 一般的な EM アルゴリズムの取り扱いを調べた
- EM アルゴリズムに対する次の疑問を解決した
  - $\ln p(\mathbf{X}|\boldsymbol{\theta})$  の代わりに、 $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  を最大化してもよい根拠
  - $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  の、 $p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})$  による期待値を取る理由
  - E ステップと M ステップが、対数尤度関数  $\ln p(\mathbf{X}|\boldsymbol{\theta})$  を増加させる理由

- これからの話の流れ

- MAP 推定に対する EM アルゴリズムの適用を考える
- EM アルゴリズムの拡張 (一般化 EM アルゴリズム) について簡単に触れる
- 混合ガウスモデルについて、逐次型の EM アルゴリズムを導出する

## 1 EM アルゴリズム

- EM アルゴリズムの解釈
- 混合ガウス分布の再解釈
- K-Means 法との関連
- 一般の EM アルゴリズム
- MAP 推定に対する EM アルゴリズム
- EM アルゴリズムの拡張
- EM アルゴリズムに関する補足
- 逐次型の EM アルゴリズム

# MAP 推定に対する EM アルゴリズム

- 事後分布の対数  $\ln p(\boldsymbol{\theta}|\mathbf{X})$  の最大化
  - 今までは、尤度関数  $\ln p(\mathbf{X}|\boldsymbol{\theta})$  の最適化を考えてきた
  - 即ち、**最尤推定に対する EM アルゴリズム**を考えてきた
- パラメータの事前分布  $p(\boldsymbol{\theta})$  を導入したモデルであれば、最尤推定だけでなく **MAP 推定**に対しても、EM アルゴリズムを使える
- MAP 推定とは、次式のように、事後分布  $p(\boldsymbol{\theta}|\mathbf{X})$  を最大化するパラメータ  $\boldsymbol{\theta}^*$  を求める問題である

$$\boldsymbol{\theta}^* = \arg \max_{\boldsymbol{\theta}} p(\boldsymbol{\theta}|\mathbf{X}) \quad (105)$$

$$= \arg \max_{\boldsymbol{\theta}} \frac{p(\mathbf{X}, \boldsymbol{\theta})}{p(\mathbf{X})} \quad (106)$$

$$= \arg \max_{\boldsymbol{\theta}} \frac{p(\mathbf{X}|\boldsymbol{\theta})p(\boldsymbol{\theta})}{p(\mathbf{X})} \quad (107)$$

$$= \arg \max_{\boldsymbol{\theta}} p(\mathbf{X}|\boldsymbol{\theta})p(\boldsymbol{\theta}) \quad (108)$$

# MAP 推定に対する EM アルゴリズム

- 事後分布の対数  $\ln p(\boldsymbol{\theta}|\mathbf{X})$  は

$$\ln p(\boldsymbol{\theta}|\mathbf{X}) = \ln \frac{p(\mathbf{X}, \boldsymbol{\theta})}{p(\mathbf{X})} \quad (109)$$

$$\begin{aligned} &= \ln \frac{p(\mathbf{X}|\boldsymbol{\theta})p(\boldsymbol{\theta})}{p(\mathbf{X})} \\ &= \ln p(\mathbf{X}|\boldsymbol{\theta}) + \ln p(\boldsymbol{\theta}) - p(\mathbf{X}) \end{aligned} \quad (110)$$

$$= \mathcal{L}(q, \boldsymbol{\theta}) + \text{KL}(q||p) + \ln p(\boldsymbol{\theta}) - p(\mathbf{X}) \quad (111)$$

$$\geq \mathcal{L}(q, \boldsymbol{\theta}) + \ln p(\boldsymbol{\theta}) - p(\mathbf{X}) \quad (112)$$

$$= \mathcal{L}(q, \boldsymbol{\theta}) + \ln p(\boldsymbol{\theta}) + \text{Const.} \quad (113)$$

- $\ln p(\mathbf{X})$  は定数とみなせるから、 $\ln p(\boldsymbol{\theta}|\mathbf{X})$  の最大化は、結局  $\mathcal{L}(q, \boldsymbol{\theta}) + \ln p(\boldsymbol{\theta})$  の最大化に相当する

# MAP 推定に対する EM アルゴリズム

- MAP 推定に対する EM アルゴリズム

- **E ステップ**では、パラメータ  $\theta$  を固定しつつ、 $q$  について  $\mathcal{L}(q, \theta)$  を最大化する
- $q$  は下界  $\mathcal{L}(q, \theta)$  にしか現れないので、**通常の EM アルゴリズムと全く同様**である
- **M ステップ**では、分布  $q$  を固定しつつ、パラメータ  $\theta$  について  $\mathcal{L}(q, \theta) + \ln p(\theta)$  を最大化する
- 事前分布の項  $\ln p(\theta)$  が現れているが、大抵は、通常の最尤推定に関する EM アルゴリズムと、少ししか変わらない

## 1 EM アルゴリズム

- EM アルゴリズムの解釈
- 混合ガウス分布の再解釈
- K-Means 法との関連
- 一般の EM アルゴリズム
- MAP 推定に対する EM アルゴリズム
- **EM アルゴリズムの拡張**
- EM アルゴリズムに関する補足
- 逐次型の EM アルゴリズム

# EM アルゴリズムの拡張

- EM アルゴリズムに対する懸念

- EM アルゴリズムは、潜在的に困難である尤度関数  $\ln p(\mathbf{X}|\theta)$  の最大化を、**E ステップ**と **M ステップ**の2つに分解してくれる
- この2つのステップは多くの場合、実装が単純になる
- 但し、複雑なモデルに対しては、2つのどちらかのステップが、**依然として手に負えないかもしれない**

- 一般化 EM アルゴリズム

- 手に負えない M ステップに対処するためのアルゴリズム
- M ステップで、下界  $\mathcal{L}(q, \theta)$  を  $\theta$  について**最大化するのは諦める**代わりに、下界  $\mathcal{L}(q, \theta)$  を**少しでも増加させるように**、 $\theta$  を更新する
- $\mathcal{L}(q, \theta)$  は、**常に**尤度関数  $\ln p(\mathbf{X}|\theta)$  の下界であるから、 $\mathcal{L}$  を押し上げることは、尤度関数の増加につながる



# EM アルゴリズムの拡張

- M ステップで制限付きの最適化を行うことができる
- パラメータ  $\theta$  を幾つかのグループに分割
- 各グループに属するパラメータを、他のグループに属するパラメータを固定しながら、順番に最適化していく

## 1 EM アルゴリズム

- EM アルゴリズムの解釈
- 混合ガウス分布の再解釈
- K-Means 法との関連
- 一般の EM アルゴリズム
- MAP 推定に対する EM アルゴリズム
- EM アルゴリズムの拡張
- EM アルゴリズムに関する補足
- 逐次型の EM アルゴリズム

# パラメータについての補足

- パラメータ  $\theta$  についての補足

- 任意の  $\theta$  について、下界  $\mathcal{L}(q, \theta)$  は  $q$  について**唯一の最大点**をもつ
- それは事後分布  $q(\mathbf{Z}) = p(\mathbf{Z}|\mathbf{X}, \theta)$  である
- またこのとき、下界  $\mathcal{L}$  は対数尤度関数  $\ln p(\mathbf{X}|\theta)$  に一致する
- $\theta$  が下界  $\mathcal{L}(q, \theta)$  の大域的最適解に収束するなら、そのような  $\theta$  は、対数尤度関数  $\ln p(\mathbf{X}|\theta)$  の大域的最適解でもある
- 任意の下界  $\mathcal{L}(q, \theta)$  の任意の極大点は、 $\ln p(\mathbf{X}|\theta)$  の極大点でもある

## 1 EM アルゴリズム

- EM アルゴリズムの解釈
- 混合ガウス分布の再解釈
- K-Means 法との関連
- 一般の EM アルゴリズム
- MAP 推定に対する EM アルゴリズム
- EM アルゴリズムの拡張
- EM アルゴリズムに関する補足
- 逐次型の EM アルゴリズム

# 逐次型の EM アルゴリズムの例

- 混合ガウスモデルに対する逐次型の EM アルゴリズム
  - E ステップでは、事後確率分布  $p(Z|X, \theta)$  を計算する
  - データが **i.i.d 集合** であれば、次のように、各データ点ごとの事後確率  $p(z_i|x_i, \theta)$  の積として分解できる

$$p(Z|X, \theta) = \prod_i p(z_i|x_i, \theta) \quad (114)$$

- このとき、**全てのデータ点**  $X$  に対して事後確率を求める必要がある
- これを、**1つのデータ点** についてだけ事後確率を求めるように変更する
- M ステップでも、1つのデータ点に対して求めた事後確率だけを使って、パラメータを逐次的に更新するように変更を加える
- 混合ガウスモデルであれば、逐次的な更新式を導出することが可能

# 逐次型の EM アルゴリズムの例

- 従って、全てのデータ点に対する事後確率を使って、パラメータを再計算する必要がない
- これらの変更によって、**逐次版の EM アルゴリズム**を導出できる
- 混合ガウスモデルに対する逐次型の EM アルゴリズムの導出
  - データ点  $x_m$  について、事後確率 (負担率)  $\gamma(z_{mk})$  を更新したとする
  - 新しい負担率を  $\gamma^{\text{new}}(z_{mk})$ 、以前の負担率を  $\gamma^{\text{old}}(z_{mk})$  とする
  - $d$  を次のようにおく (前後の負担率の差)

$$d = \gamma^{\text{new}}(z_{mk}) - \gamma^{\text{old}}(z_{mk}) \quad (115)$$

- $N_k^{\text{new}}$  を次のようにおく (クラス  $k$  に属するデータの、実質的な個数)

$$N_k^{\text{new}} = N_k^{\text{old}} + \gamma^{\text{new}}(z_{mk}) - \gamma^{\text{old}}(z_{mk}) = N_k^{\text{old}} + d \quad (116)$$

# 逐次型の EM アルゴリズムの例

- 以前の平均  $\boldsymbol{\mu}_k^{\text{old}}$ 、共分散行列  $\boldsymbol{\Sigma}_k^{\text{old}}$ 、混合係数  $\pi_k^{\text{old}}$  を、以下のように書くことにする

$$\boldsymbol{\mu}_k^{\text{old}} = \frac{1}{N_k^{\text{old}}} \sum_i \gamma^{\text{old}}(z_{ik}) \mathbf{x}_i \quad (117)$$

$$\boldsymbol{\Sigma}_k^{\text{old}} = \frac{1}{N_k^{\text{old}}} \sum_i \gamma^{\text{old}}(z_{ik}) (\mathbf{x}_i - \boldsymbol{\mu}_k^{\text{old}})(\mathbf{x}_i - \boldsymbol{\mu}_k^{\text{old}})^T \quad (118)$$

$$\pi_k^{\text{old}} = \frac{N_k^{\text{old}}}{N} \quad (119)$$

但し

$$N_k^{\text{old}} = \sum_i \gamma^{\text{old}}(z_{ik}) \quad (120)$$

# 逐次型の EM アルゴリズムの例

- 平均の更新式は

$$\boldsymbol{\mu}_k^{\text{new}} = \frac{1}{N_k^{\text{new}}} \left( \sum_{i \neq m} \gamma^{\text{old}}(z_{ik}) \mathbf{x}_i + \gamma^{\text{new}}(z_{mk}) \mathbf{x}_m \right) \quad (121)$$

$$= \frac{1}{N_k^{\text{new}}} \left( N_k^{\text{old}} \boldsymbol{\mu}_k^{\text{old}} - \gamma^{\text{old}}(z_{mk}) \mathbf{x}_m + \gamma^{\text{new}}(z_{mk}) \mathbf{x}_m \right)$$

$$= \frac{1}{N_k^{\text{new}}} \left( (N_k^{\text{new}} - \gamma^{\text{new}}(z_{mk}) + \gamma^{\text{old}}(z_{mk})) \boldsymbol{\mu}_k^{\text{old}} - \gamma^{\text{old}}(z_{mk}) \mathbf{x}_m + \gamma^{\text{new}}(z_{mk}) \mathbf{x}_m \right)$$

$$= \boldsymbol{\mu}_k^{\text{old}} + \frac{1}{N_k^{\text{new}}} \left( -(\gamma^{\text{new}}(z_{mk}) - \gamma^{\text{old}}(z_{mk})) \boldsymbol{\mu}_k^{\text{old}} + (\gamma^{\text{new}}(z_{mk}) - \gamma^{\text{old}}(z_{mk})) \mathbf{x}_m \right)$$

$$= \boldsymbol{\mu}_k^{\text{old}} + \frac{\gamma^{\text{new}}(z_{mk}) - \gamma^{\text{old}}(z_{mk})}{N_k^{\text{new}}} (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}}) \quad (122)$$



# 逐次型の EM アルゴリズムの例

$$= \boldsymbol{\mu}_k^{\text{old}} + \frac{d}{N_k^{\text{new}}} (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}}) \quad (123)$$

- 分散の更新式は

$$\boldsymbol{\Sigma}_k^{\text{new}} = \frac{1}{N_k^{\text{new}}} \sum_i \gamma^{\text{new}}(z_{ik}) \mathbf{x}_i \mathbf{x}_i^T - \boldsymbol{\mu}_k^{\text{new}} (\boldsymbol{\mu}_k^{\text{new}})^T \quad (124)$$

$$= \frac{1}{N_k^{\text{new}}} \left( \sum_{i \neq m} \gamma^{\text{old}}(z_{ik}) \mathbf{x}_i \mathbf{x}_i^T + \gamma^{\text{new}}(z_{mk}) \mathbf{x}_m \mathbf{x}_m^T \right) - \boldsymbol{\mu}_k^{\text{new}} (\boldsymbol{\mu}_k^{\text{new}})^T \quad (125)$$

$$= \frac{1}{N_k^{\text{new}}} \left( \left( \sum_i \gamma^{\text{old}}(z_{ik}) \mathbf{x}_i \mathbf{x}_i^T - \gamma^{\text{old}}(z_{mk}) \mathbf{x}_m \mathbf{x}_m^T \right) + \gamma^{\text{new}}(z_{mk}) \mathbf{x}_m \mathbf{x}_m^T \right) - \boldsymbol{\mu}_k^{\text{new}} (\boldsymbol{\mu}_k^{\text{new}})^T \quad (126)$$

# 逐次型の EM アルゴリズムの例

$$\begin{aligned} &= \frac{1}{N_k^{\text{new}}} \left( N_k^{\text{old}} \left( \boldsymbol{\Sigma}_k^{\text{old}} + \boldsymbol{\mu}_k^{\text{old}} (\boldsymbol{\mu}_k^{\text{old}})^T \right) - \right. \\ &\quad \left. \gamma^{\text{old}}(z_{mk}) \mathbf{x}_m \mathbf{x}_m^T + \gamma^{\text{new}}(z_{mk}) \mathbf{x}_m \mathbf{x}_m^T \right) - \\ &\quad \boldsymbol{\mu}_k^{\text{new}} (\boldsymbol{\mu}_k^{\text{new}})^T \end{aligned} \quad (127)$$

$$\begin{aligned} &= \frac{1}{N_k^{\text{new}}} \left( N_k^{\text{old}} \boldsymbol{\Sigma}_k^{\text{old}} + N_k^{\text{old}} \boldsymbol{\mu}_k^{\text{old}} (\boldsymbol{\mu}_k^{\text{old}})^T + \right. \\ &\quad \left( \gamma^{\text{new}}(z_{mk}) - \gamma^{\text{old}}(z_{mk}) \right) \mathbf{x}_m \mathbf{x}_m^T - \\ &\quad \left. N_k^{\text{new}} \boldsymbol{\mu}_k^{\text{new}} (\boldsymbol{\mu}_k^{\text{new}})^T \right) \\ &= \frac{1}{N_k^{\text{new}}} \left( N_k^{\text{old}} \boldsymbol{\Sigma}_k^{\text{old}} + N_k^{\text{old}} \boldsymbol{\mu}_k^{\text{old}} (\boldsymbol{\mu}_k^{\text{old}})^T + \right. \\ &\quad \left. d\mathbf{x}_m \mathbf{x}_m^T - N_k^{\text{new}} \boldsymbol{\mu}_k^{\text{new}} (\boldsymbol{\mu}_k^{\text{new}})^T \right) \end{aligned} \quad (128)$$

# 逐次型の EM アルゴリズムの例

ここで

$$\begin{aligned} & N_k^{\text{new}} \boldsymbol{\mu}_k^{\text{new}} (\boldsymbol{\mu}_k^{\text{new}})^T \\ = & (N_k^{\text{new}} \boldsymbol{\mu}_k^{\text{old}} + d(\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}})) (\boldsymbol{\mu}_k^{\text{new}})^T \\ = & \frac{1}{N_k^{\text{new}}} (N_k^{\text{new}} \boldsymbol{\mu}_k^{\text{old}} + d(\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}})) \\ & (N_k^{\text{new}} \boldsymbol{\mu}_k^{\text{old}} + d(\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}}))^T \\ = & N_k^{\text{new}} \boldsymbol{\mu}_k^{\text{old}} (\boldsymbol{\mu}_k^{\text{old}})^T + 2\boldsymbol{\mu}_k^{\text{old}} d(\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}})^T + \\ & \frac{1}{N_k^{\text{new}}} d^2 (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}}) (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}})^T \end{aligned} \quad (129)$$

$$\begin{aligned} = & (N_k^{\text{old}} + d) \boldsymbol{\mu}_k^{\text{old}} (\boldsymbol{\mu}_k^{\text{old}})^T + \\ & 2d \boldsymbol{\mu}_k^{\text{old}} \mathbf{x}_m^T - 2d \boldsymbol{\mu}_k^{\text{old}} (\boldsymbol{\mu}_k^{\text{old}})^T + \\ & \frac{1}{N_k^{\text{new}}} d^2 (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}}) (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}})^T \end{aligned} \quad (130)$$

# 逐次型の EM アルゴリズムの例

であるから

$$\begin{aligned} & N_k^{\text{old}} \boldsymbol{\mu}_k^{\text{old}} (\boldsymbol{\mu}_k^{\text{old}})^T + d \mathbf{x}_m \mathbf{x}_m^T - N_k^{\text{new}} \boldsymbol{\mu}_k^{\text{new}} (\boldsymbol{\mu}_k^{\text{new}})^T \\ = & N_k^{\text{old}} \boldsymbol{\mu}_k^{\text{old}} (\boldsymbol{\mu}_k^{\text{old}})^T + d \mathbf{x}_m \mathbf{x}_m^T - \\ & (N_k^{\text{old}} + d) \boldsymbol{\mu}_k^{\text{old}} (\boldsymbol{\mu}_k^{\text{old}})^T - \\ & 2d \boldsymbol{\mu}_k^{\text{old}} \mathbf{x}_m^T + 2d \boldsymbol{\mu}_k^{\text{old}} (\boldsymbol{\mu}_k^{\text{old}})^T - \\ & \frac{1}{N_k^{\text{new}}} d^2 (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}}) (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}})^T \\ = & d \mathbf{x}_m \mathbf{x}_m^T + d \boldsymbol{\mu}_k^{\text{old}} (\boldsymbol{\mu}_k^{\text{old}})^T - 2d \boldsymbol{\mu}_k^{\text{old}} \mathbf{x}_m^T - \\ & \frac{1}{N_k^{\text{new}}} d^2 (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}}) (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}})^T \\ = & d (\mathbf{x}_m \mathbf{x}_m^T + \boldsymbol{\mu}_k^{\text{old}} (\boldsymbol{\mu}_k^{\text{old}})^T - 2 \boldsymbol{\mu}_k^{\text{old}} \mathbf{x}_m^T) - \\ & \frac{1}{N_k^{\text{new}}} d^2 (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}}) (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}})^T \\ = & d (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}}) (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}})^T - \end{aligned}$$

## 逐次型の EM アルゴリズムの例

$$\begin{aligned} & \frac{1}{N_k^{\text{new}}} d^2 (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}}) (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}})^T \\ = & \frac{d}{N_k^{\text{new}}} (N_k^{\text{new}} - d) (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}}) (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}})^T \\ = & \frac{d}{N_k^{\text{new}}} N_k^{\text{old}} (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}}) (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}})^T \end{aligned} \quad (131)$$

以上より

$$\begin{aligned} \boldsymbol{\Sigma}_k^{\text{new}} &= \frac{1}{N_k^{\text{new}}} \left( N_k^{\text{old}} \boldsymbol{\Sigma}_k^{\text{old}} + N_k^{\text{old}} \boldsymbol{\mu}_k^{\text{old}} (\boldsymbol{\mu}_k^{\text{old}})^T + \right. \\ & \quad \left. d \mathbf{x}_m \mathbf{x}_m^T - N_k^{\text{new}} \boldsymbol{\mu}_k^{\text{new}} (\boldsymbol{\mu}_k^{\text{new}})^T \right) \\ &= \frac{1}{N_k^{\text{new}}} \left( N_k^{\text{old}} \boldsymbol{\Sigma}_k^{\text{old}} + \right. \\ & \quad \left. \frac{d}{N_k^{\text{new}}} N_k^{\text{old}} (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}}) (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}})^T \right) \end{aligned}$$

## 逐次型の EM アルゴリズムの例

$$\begin{aligned} &= \frac{N_k^{\text{old}}}{N_k^{\text{new}}} \left( \boldsymbol{\Sigma}_k^{\text{old}} + \frac{d}{N_k^{\text{new}}} \right. \\ &\quad \left. (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}}) (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}})^T \right) \\ &= \frac{N_k^{\text{old}}}{N_k^{\text{new}}} \left( \boldsymbol{\Sigma}_k^{\text{old}} + \frac{\gamma^{\text{new}}(z_{ik}) - \gamma^{\text{old}}(z_{ik})}{N_k^{\text{new}}} \right. \\ &\quad \left. (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}}) (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}})^T \right) \end{aligned} \quad (132)$$

- 混合係数の更新式は

$$\pi_k^{\text{new}} = \frac{N_k^{\text{new}}}{N} = \frac{N_k^{\text{old}} + \gamma^{\text{new}}(z_{mk}) - \gamma^{\text{old}}(z_{mk})}{N} \quad (133)$$

# 逐次型の EM アルゴリズムの例

- 混合ガウスモデルにおける逐次型の EM アルゴリズム
  - 上記より、パラメータ  $\mu_k, \Sigma_k, \pi_k$  の逐次更新式が得られた

$$\mu_k^{\text{new}} = \mu_k^{\text{old}} + \frac{\gamma^{\text{new}}(z_{mk}) - \gamma^{\text{old}}(z_{mk})}{N_k^{\text{new}}} (\mathbf{x}_m - \mu_k^{\text{old}}) \quad (134)$$

$$\Sigma_k^{\text{new}} = \frac{N_k^{\text{old}}}{N_k^{\text{new}}} \left( \Sigma_k^{\text{old}} + \frac{\gamma^{\text{new}}(z_{ik}) - \gamma^{\text{old}}(z_{ik})}{N_k^{\text{new}}} (\mathbf{x}_m - \mu_k^{\text{old}}) (\mathbf{x}_m - \mu_k^{\text{old}})^T \right) \quad (135)$$

$$\pi_k^{\text{new}} = \frac{N_k^{\text{new}}}{N} = \frac{N_k^{\text{old}} + \gamma^{\text{new}}(z_{mk}) - \gamma^{\text{old}}(z_{mk})}{N} \quad (136)$$

但し

$$N_k^{\text{new}} = N_k^{\text{old}} + \gamma^{\text{new}}(z_{mk}) - \gamma^{\text{old}}(z_{mk}) \quad (137)$$

# 逐次型の EM アルゴリズムの例

- 到着したデータ  $x_m$  について、E ステップで負担率  $\gamma(z_{mk})$  を求めた後に、M ステップで (上記の更新式を用いて) パラメータを更新することを、交互に繰り返せばよい
- 逐次型の EM アルゴリズムの特徴
  - $x_m$  が新しく到着したデータであれば、 $\gamma^{\text{old}}(z_{mk}) = 0$  とする
  - E ステップと M ステップの計算に必要な時間は、データ点の総数とは無関係に決まる
  - パラメータの更新は、全データについての処理を待たずに、各データ点についての処理の後に行われる
  - そのため、逐次型の EM アルゴリズムは、従来のバッチ型に比べて、**速く収束する**



# 逐次型の EM アルゴリズムの例

- ここまでの話の流れ
  - MAP 推定に対する EM アルゴリズムについて考えた
  - EM アルゴリズムの拡張 (一般化 EM アルゴリズム) について簡単に触れた
  - 混合ガウスモデルについて、逐次型の EM アルゴリズムを導出した

# EM アルゴリズムのまとめ

- EM アルゴリズムの目的

- 潜在変数をもつ確率モデルについて、パラメータの最尤解を求める

- EM アルゴリズムで行っていること

- 対数尤度  $\ln p(\mathbf{X}|\boldsymbol{\theta})$  の直接の最適化が困難であっても、E ステップと M ステップという 2 段階の簡単な手続きに分割し、交互に繰り返すことで最適化できるようにする
- 完全データ対数尤度  $\ln p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta})$  の事後確率  $\ln p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta})$  による期待値  $Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}})$  の最大化を行う
- 期待値の最大化は、 $\mathcal{L}(q, \boldsymbol{\theta})$  の最大化と等価である
- $\mathcal{L}(q, \boldsymbol{\theta})$  は  $\ln p(\mathbf{X}|\boldsymbol{\theta})$  の下界であるから、 $\mathcal{L}$  の最大化は、対数尤度  $\ln p(\mathbf{X}|\boldsymbol{\theta})$  の最大化に相当

# EM アルゴリズムのまとめ

- ここまでの話の流れ

- 発見的に導出した、混合ガウスモデルに対する EM アルゴリズムも、期待値の最大化という考え方で解釈可能であった
- K-Means 法は、混合ガウスモデルに対する EM アルゴリズムの一種の極限として得られた
- 一般的な EM アルゴリズムの取り扱いについて調べた
- 最尤推定だけでなく、MAP 推定に対しても EM アルゴリズムを適用できた
- 混合ガウスモデルに対する、逐次版の EM アルゴリズムを導出した