

① EM アルゴリズムの例

1 EM アルゴリズムの例

- 確率的主成分分析 (PPCA)
- 確率的主成分分析 (PPCA) のまとめ

確率的主成分分析 (PPCA)

- 主成分分析の確率モデルによる表現
 - 主成分分析は、潜在変数を含む確率モデルの、最尤推定として導出できることを示す
 - このような主成分分析の再定式化を**確率的主成分分析**という
 - そして、主成分分析を行うための **EM アルゴリズム**を導出してみる

確率的主成分分析 (PPCA)

- 主成分分析の確率モデルによる表現

- 主成分分析では、 D 個の変数 $\{x_1, x_2, \dots, x_D\}$ を線形に組み合わせて、**真にアクティブな M 個の変数**を見いだす
- 主部分空間に存在する潜在変数を、 M 次元のベクトル z として明示的に表現する
- D 次元のデータ x は、主部分空間内の M 次元のベクトル z から、以下のように、ガウス分布から**確率的に**生成されたと考える

$$p(x|z) = \mathcal{N}(x|Wz + \mu, \sigma^2 I) \quad (1)$$

- $D \times M$ 行列 W の列ベクトルが張る空間 (線形部分空間) は、データ空間における**主部分空間に対応**する
- D 次ベクトル μ は、観測変数 x の平均である

確率的主成分分析 (PPCA)

- 潜在変数 z に関する事前分布 $p(z)$ も、平均 0 で共分散行列が単位行列 I のガウス分布とする

$$p(z) = \mathcal{N}(z|0, I) \quad (2)$$

- 事前分布 $p(z)$ の平均が 0 、共分散行列が I でも、一般性は失われている
- 事前分布 $p(z)$ として、より一般的なガウス分布を仮定しても、得られる確率モデルは結果的に等価になる
- **生成モデル**の観点から、確率的主成分分析モデルを考えることができる

確率的主成分分析 (PPCA)

- 生成モデルの観点

- 生成モデルとは、実際に観測されるデータ x が、**どのように生成されるか**という過程を、確率分布などを使ってモデル化したものである
- ここでは、潜在変数 z を含んだ生成モデルを考えている

- データの生成過程

- 1 潜在変数 z_i を、事前分布 $p(z)$ からサンプリングする
- 2 z_i を使って、条件付き分布 $p(x|z)$ からデータ x_i をサンプリングする

- データの生成過程に関する注意点

- D 次元の観測変数 x_i は、 M 次元の潜在変数 z_i に**線形変換**を施したあと $(x_i = Wz_i + \mu)$ 、ガウス分布による**ノイズ** ($\epsilon_i \sim \mathcal{N}(\epsilon|0, \sigma^2 I)$) が加えられたものとして定義される $(x_i = Wz_i + \mu_i + \epsilon_i)$
- 観測変数 x_i の裏側には、潜在変数 z_i が潜んでいる
- 潜在変数 z_i は実際に観測できないが、 x_i の本質的な情報を表している

確率的主成分分析 (PPCA)

- パラメータ W, μ, σ^2 の最尤推定
 - 観測変数 x_i の裏側には、潜在変数 z_i が対応している
 - パラメータ W, μ, σ^2 を通じて、 z_i から観測可能な x_i が生成される
 - パラメータの最尤推定を行うために、尤度関数 $p(x|W, \mu, \sigma^2)$ を求める
 - $p(x|W, \mu, \sigma^2)$ は、 x と z に関する同時分布 $p(x, z|W, \mu, \sigma^2)$ の、 z に関する周辺化によって得られる

$$p(x|W, \mu, \sigma^2) = \int p(x|z, W, \mu, \sigma^2)p(z)dz \quad (3)$$

- $p(x|z, W, \mu, \sigma^2)$ と $p(z)$ は、いずれもガウス分布であったので、ガウス分布に関する公式から $p(x|W, \mu, \sigma^2)$ は次のようになる

$$p(x|W, \mu, \sigma^2) = \mathcal{N}(x|\mu, C) \quad (4)$$

確率的主成分分析 (PPCA)

- 行列 C は次のように定義される

$$C = WW^T + \sigma^2 I \quad (5)$$

- 更に、潜在変数 z に関する事後分布 $p(z|x)$ も計算できる

$$p(z|x, W, \mu, \sigma^2) = \mathcal{N}(z|M^{-1}W^T(x - \mu), \sigma^2 M^{-1}) \quad (6)$$

- 行列 M は次のように定義される

$$M = W^T W + \sigma^2 I \quad (7)$$

- これらの式は、ガウス分布に関する次の公式を用いれば導出できる

$$p(y|x) = \mathcal{N}(y|Ax + b, D) \quad (8)$$

$$p(x) = \mathcal{N}(x|\mu, \Sigma) \quad (9)$$

確率的主成分分析 (PPCA)

- $p(\mathbf{y}|\mathbf{x})$ と $p(\mathbf{x})$ が上式のようなガウス分布であるとき、 $p(\mathbf{x}|\mathbf{y})$ と $p(\mathbf{y})$ は次のようになる

$$p(\mathbf{x}|\mathbf{y}) = \mathcal{N}(\mathbf{x} | \mathbf{M}(\mathbf{A}^T \mathbf{D}^{-1}(\mathbf{y} - \mathbf{b}) + \Sigma^{-1} \boldsymbol{\mu}), \mathbf{M}) \quad (10)$$

$$p(\mathbf{y}) = \mathcal{N}(\mathbf{y} | \mathbf{A} \boldsymbol{\mu} + \mathbf{b}, \mathbf{D} + \mathbf{A} \Sigma \mathbf{A}^T) \quad (11)$$

$$\mathbf{M} = (\mathbf{A}^T \mathbf{D}^{-1} \mathbf{A} + \Sigma^{-1})^{-1} \quad (12)$$

確率的主成分分析 (PPCA)

- パラメータ μ に関する最尤推定

- N 個の観測データ $\{x_1, \dots, x_N\}$ と、それに対応する潜在変数 $\{z_1, \dots, z_N\}$ を考える
- ここでの目標は、データ $\mathcal{D} = \{x_1, \dots, x_N\}$ から、パラメータ W, μ, σ^2 を最尤推定することである
- N 個のデータをまとめた行列を X とする (第 i 行ベクトルは x_i^T)
- N 個の潜在変数をまとめた行列を Z とする (第 i 行ベクトルは z_i^T)
- 各データと潜在変数 x_i, z_i は、分布 $p(x|z), p(z)$ から独立にサンプリングされたとする (データは **i.i.d 標本**であるとする)

確率的主成分分析 (PPCA)

- 対数尤度関数 $\ln p(\mathbf{X}|\mathbf{W}, \boldsymbol{\mu}, \sigma^2)$ は次のように書ける

$$\begin{aligned} & \ln p(\mathbf{X}|\mathbf{W}, \boldsymbol{\mu}, \sigma^2) \\ = & \ln \prod_i p(\mathbf{x}_i|\mathbf{W}, \boldsymbol{\mu}, \sigma^2) \\ = & \sum_i \ln p(\mathbf{x}_i|\mathbf{W}, \boldsymbol{\mu}, \sigma^2) \\ = & \sum_i \ln \mathcal{N}(\mathbf{x}_i|\boldsymbol{\mu}, \mathbf{C}) \\ = & \sum_i \ln \frac{1}{(2\pi)^{\frac{D}{2}}} \frac{1}{|\mathbf{C}|^{\frac{1}{2}}} \exp\left(-\frac{1}{2}(\mathbf{x}_i - \boldsymbol{\mu})^T \mathbf{C}^{-1}(\mathbf{x}_i - \boldsymbol{\mu})\right) \\ = & \sum_i \left(-\frac{D}{2} \ln 2\pi - \frac{1}{2} \ln |\mathbf{C}| - \frac{1}{2}(\mathbf{x}_i - \boldsymbol{\mu})^T \mathbf{C}^{-1}(\mathbf{x}_i - \boldsymbol{\mu})\right) \\ = & -\frac{ND}{2} \ln 2\pi - \frac{N}{2} \ln |\mathbf{C}| - \frac{1}{2} \sum_i (\mathbf{x}_i - \boldsymbol{\mu})^T \mathbf{C}^{-1}(\mathbf{x}_i - \boldsymbol{\mu}) \end{aligned}$$

確率的主成分分析 (PPCA)

- 対数尤度を μ で偏微分し、0 と等置することによって、 μ の最尤解が得られる

$$\begin{aligned} & \frac{\partial}{\partial \mu} \ln p(\mathbf{X} | \mathbf{W}, \mu, \sigma^2) \\ &= -\frac{1}{2} \frac{\partial}{\partial \mu} \sum_i (\mathbf{x}_i - \mu)^T \mathbf{C}^{-1} (\mathbf{x}_i - \mu) \\ &= -\frac{1}{2} \sum_i (-2\mathbf{C}^{-1}) (\mathbf{x}_i - \mu) \\ &= \mathbf{C}^{-1} \sum_i (\mathbf{x}_i - \mu) \\ &= 0 \end{aligned}$$

これより μ の最尤解は以下のようなになる

$$\mu = \frac{1}{N} \sum_i \mathbf{x}_i \quad (13)$$

確率的主成分分析 (PPCA)

- パラメータ W, σ^2 に関する最尤推定
 - 対数尤度を W, σ^2 について微分することは形式上は可能である
 - 但し、 W, σ^2 が行列 C の中に入れ子になっている
 - 従って、 W, σ^2 の厳密な閉形式の解を得ることは、複雑かつ困難である
- そこで、パラメータ W, σ^2 を求めるための **EM アルゴリズム** を導出したい
- EM アルゴリズムは、潜在変数を含む確率モデルについて、パラメータの最尤推定を行うための一般的な枠組みを提供する

確率的主成分分析 (PPCA)

- EM アルゴリズムによる主成分分析の導出
 - 完全データ対数尤度関数 $\ln p(\mathbf{X}, \mathbf{Z} | \mathbf{W}, \boldsymbol{\mu}, \sigma^2)$ は次のようになる

$$\begin{aligned} & \ln p(\mathbf{X}, \mathbf{Z} | \mathbf{W}, \boldsymbol{\mu}, \sigma^2) \\ = & \ln \prod_i p(\mathbf{x}_i, \mathbf{z}_i | \mathbf{W}, \boldsymbol{\mu}, \sigma^2) \\ = & \sum_i \ln p(\mathbf{x}_i, \mathbf{z}_i | \mathbf{W}, \boldsymbol{\mu}, \sigma^2) \\ = & \sum_i \ln p(\mathbf{x}_i | \mathbf{z}_i, \mathbf{W}, \boldsymbol{\mu}, \sigma^2) p(\mathbf{z}_i) \\ = & \sum_i \ln \mathcal{N}(\mathbf{x}_i | \mathbf{W} \mathbf{z}_i + \boldsymbol{\mu}, \sigma^2 \mathbf{I}) \mathcal{N}(\mathbf{z}_i | \mathbf{0}, \mathbf{I}) \\ = & \sum_i (\ln \mathcal{N}(\mathbf{x}_i | \mathbf{W} \mathbf{z}_i + \boldsymbol{\mu}, \sigma^2 \mathbf{I}) + \ln \mathcal{N}(\mathbf{z}_i | \mathbf{0}, \mathbf{I})) \quad (14) \end{aligned}$$

確率の主成分分析 (PPCA)

第 1 項 $\ln \mathcal{N}(\mathbf{x}_i | \mathbf{W} \mathbf{z}_i + \boldsymbol{\mu}, \sigma^2 \mathbf{I})$ は次のようになる

$$\begin{aligned} & \ln \mathcal{N}(\mathbf{x}_i | \mathbf{W} \mathbf{z}_i + \boldsymbol{\mu}, \sigma^2 \mathbf{I}) \\ = & \ln \left(\frac{1}{(2\pi)^{\frac{D}{2}}} \frac{1}{|\sigma^2 \mathbf{I}|^{\frac{1}{2}}} \right. \\ & \left. \exp \left(-\frac{1}{2} (\mathbf{x}_i - \mathbf{W} \mathbf{z}_i - \boldsymbol{\mu})^T (\sigma^2 \mathbf{I})^{-1} (\mathbf{x}_i - \mathbf{W} \mathbf{z}_i - \boldsymbol{\mu}) \right) \right) \\ = & -\frac{D}{2} \ln 2\pi - \frac{1}{2} \ln |\sigma^2 \mathbf{I}| - \\ & \frac{1}{2} (\mathbf{x}_i - \mathbf{W} \mathbf{z}_i - \boldsymbol{\mu})^T (\sigma^2 \mathbf{I})^{-1} (\mathbf{x}_i - \mathbf{W} \mathbf{z}_i - \boldsymbol{\mu}) \\ = & -\frac{D}{2} \ln 2\pi - \frac{D}{2} \ln \sigma^2 - \\ & \frac{1}{2\sigma^2} (\mathbf{x}_i - \mathbf{W} \mathbf{z}_i - \boldsymbol{\mu})^T (\mathbf{x}_i - \mathbf{W} \mathbf{z}_i - \boldsymbol{\mu}) \\ = & -\frac{D}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} (\mathbf{x}_i - \boldsymbol{\mu})^T (\mathbf{x}_i - \boldsymbol{\mu}) + \end{aligned}$$

確率の主成分分析 (PPCA)

$$\begin{aligned} & \frac{1}{\sigma^2} (\mathbf{W} \mathbf{z}_i)^T (\mathbf{x}_i - \boldsymbol{\mu}) - \frac{1}{2\sigma^2} (\mathbf{W} \mathbf{z}_i)^T (\mathbf{W} \mathbf{z}_i) \\ = & -\frac{D}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} (\mathbf{x}_i - \boldsymbol{\mu})^T (\mathbf{x}_i - \boldsymbol{\mu}) + \\ & \frac{1}{\sigma^2} \mathbf{z}_i^T \mathbf{W}^T (\mathbf{x}_i - \boldsymbol{\mu}) - \frac{1}{2\sigma^2} \mathbf{z}_i^T \mathbf{W}^T \mathbf{W} \mathbf{z}_i \\ = & -\frac{D}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \|\mathbf{x}_i - \boldsymbol{\mu}\|^2 + \\ & \frac{1}{\sigma^2} \mathbf{z}_i^T \mathbf{W}^T (\mathbf{x}_i - \boldsymbol{\mu}) - \frac{1}{2\sigma^2} \text{Tr}(\mathbf{z}_i^T \mathbf{W}^T \mathbf{W} \mathbf{z}_i) \\ = & -\frac{D}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \|\mathbf{x}_i - \boldsymbol{\mu}\|^2 + \\ & \frac{1}{\sigma^2} \mathbf{z}_i^T \mathbf{W}^T (\mathbf{x}_i - \boldsymbol{\mu}) - \frac{1}{2\sigma^2} \text{Tr}(\mathbf{z}_i \mathbf{z}_i^T \mathbf{W}^T \mathbf{W}) \end{aligned} \quad (15)$$

第 2 項 $\ln \mathcal{N}(\mathbf{z}_i | \mathbf{0}, \mathbf{I})$ は次のようになる

$$\ln \mathcal{N}(\mathbf{z}_i | \mathbf{0}, \mathbf{I})$$

確率の主成分分析 (PPCA)

$$\begin{aligned} &= \ln \left(\frac{1}{(2\pi)^{\frac{M}{2}}} \exp \left(-\frac{1}{2} \mathbf{z}_i^T \mathbf{z}_i \right) \right) \\ &= -\frac{M}{2} \ln 2\pi - \frac{1}{2} \mathbf{z}_i^T \mathbf{z}_i \\ &= -\frac{M}{2} \ln 2\pi - \frac{1}{2} \text{Tr}(\mathbf{z}_i^T \mathbf{z}_i) \\ &= -\frac{M}{2} \ln 2\pi - \frac{1}{2} \text{Tr}(\mathbf{z}_i \mathbf{z}_i^T) \end{aligned} \tag{16}$$

これより $\ln p(\mathbf{X}, \mathbf{Z} | \mathbf{W}, \boldsymbol{\mu}, \sigma^2)$ は次のようになる

$$\begin{aligned} &\ln p(\mathbf{X}, \mathbf{Z} | \mathbf{W}, \boldsymbol{\mu}, \sigma^2) \\ &= \sum_i (\ln \mathcal{N}(\mathbf{x}_i | \mathbf{W} \mathbf{z}_i + \boldsymbol{\mu}, \sigma^2 \mathbf{I}) + \ln \mathcal{N}(\mathbf{z}_i | \mathbf{0}, \mathbf{I})) \\ &= \sum_i \left\{ -\frac{D}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \|\mathbf{x}_i - \boldsymbol{\mu}\|^2 + \right. \end{aligned}$$

確率の主成分分析 (PPCA)

$$\frac{1}{\sigma^2} \mathbf{z}_i^T \mathbf{W}^T (\mathbf{x}_i - \boldsymbol{\mu}) - \frac{1}{2\sigma^2} \text{Tr} (\mathbf{z}_i \mathbf{z}_i^T \mathbf{W}^T \mathbf{W}) - \frac{M}{2} \ln 2\pi - \frac{1}{2} \text{Tr} (\mathbf{z}_i \mathbf{z}_i^T) \Big\} \quad (17)$$

- $\boldsymbol{\mu}$ は、全データの平均として得られることが分かっている
- 従って、 $\boldsymbol{\mu}$ は既知であるとして、 $\bar{\mathbf{x}}$ と書くことにする
- 潜在変数の事後分布 $p(\mathbf{Z}|\mathbf{X}, \mathbf{W}, \boldsymbol{\mu}, \sigma^2)$ に関する期待値を取ると、次のようになる ($\mathbb{E}[\cdot]$ は、事後分布による期待値を表す)

$$\begin{aligned} & \mathbb{E} [\ln p(\mathbf{X}, \mathbf{Z}|\mathbf{W}, \boldsymbol{\mu}, \sigma^2)] \\ = & \sum_i \left\{ -\frac{D}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \|\mathbf{x}_i - \boldsymbol{\mu}\|^2 + \right. \\ & \frac{1}{\sigma^2} \mathbb{E} [\mathbf{z}_i]^T \mathbf{W}^T (\mathbf{x}_i - \boldsymbol{\mu}) - \frac{1}{2\sigma^2} \text{Tr} (\mathbb{E} [\mathbf{z}_i \mathbf{z}_i^T] \mathbf{W}^T \mathbf{W}) - \\ & \left. \frac{M}{2} \ln 2\pi - \frac{1}{2} \text{Tr} (\mathbb{E} [\mathbf{z}_i \mathbf{z}_i^T]) \right\} \quad (18) \end{aligned}$$

確率的主成分分析 (PPCA)

- 事後分布は以下のものであった ($M = W^T W + \sigma^2 I$)

$$p(z|x, W, \mu, \sigma^2) = \mathcal{N}(z | M^{-1} W^T (x - \mu), \sigma^2 M^{-1}) \quad (19)$$

- これより $\mathbb{E}[z_i]$ と $\mathbb{E}[z_i z_i^T]$ は次のようになる

$$\mathbb{E}[z_i] = M^{-1} W^T (x_i - \mu) \quad (20)$$

$$\mathbb{E}[z_i z_i^T] = \sigma^2 M^{-1} + \mathbb{E}[z_i] \mathbb{E}[z_i]^T \quad (21)$$

- $\mathbb{E}[z_i z_i^T]$ は、 $\mathbb{E}[z_i z_i^T] = \text{cov}[z_i] + \mathbb{E}[z_i] \mathbb{E}[z_i]^T$ から得られる
- $\text{cov}[z]$ は、確率変数 z の共分散行列を意味する
- E ステップ**で計算するのは、 $\mathbb{E}[z_i]$ と $\mathbb{E}[z_i z_i^T]$ の2つである
- これらの値は、古いパラメータ M, W, μ, σ^2 を使って計算される
- M ステップ**では、上記の期待値 $\mathbb{E}[\ln p(X, Z | W, \mu, \sigma^2)]$ を、各パラメータ W, σ^2 について最大化する

確率的主成分分析 (PPCA)

- 期待値を最大化するような、 \mathbf{W}, σ^2 の計算式は容易に導出できる
- \mathbf{W} について偏微分し、0 と等置すると次のようになる

$$\begin{aligned} & \frac{\partial}{\partial \mathbf{W}} \mathbb{E} [\ln p(\mathbf{X}, \mathbf{Z} | \mathbf{W}, \boldsymbol{\mu}, \sigma^2)] \\ &= \frac{\partial}{\partial \mathbf{W}} \sum_i \left\{ \frac{1}{\sigma^2} \mathbb{E} [\mathbf{z}_i]^T \mathbf{W}^T (\mathbf{x}_i - \boldsymbol{\mu}) - \frac{1}{2\sigma^2} \text{Tr} (\mathbb{E} [\mathbf{z}_i \mathbf{z}_i^T] \mathbf{W}^T \mathbf{W}) \right\} \\ &= \frac{1}{2\sigma^2} \sum_i \frac{\partial}{\partial \mathbf{W}} \left\{ 2 \mathbb{E} [\mathbf{z}_i]^T \mathbf{W}^T (\mathbf{x}_i - \boldsymbol{\mu}) - \text{Tr} (\mathbb{E} [\mathbf{z}_i \mathbf{z}_i^T] \mathbf{W}^T \mathbf{W}) \right\} \\ &= -\frac{1}{2\sigma^2} \sum_i \frac{\partial}{\partial \mathbf{W}} \left\{ 2 \text{Tr} (\mathbb{E} [\mathbf{z}_i]^T \mathbf{W}^T (\mathbf{x}_i - \boldsymbol{\mu})) - \right. \\ & \quad \left. \text{Tr} (\mathbf{W} \mathbb{E} [\mathbf{z}_i \mathbf{z}_i^T] \mathbf{W}^T) \right\} \\ &= -\frac{1}{2\sigma^2} \sum_i \frac{\partial}{\partial \mathbf{W}} \left\{ 2 \text{Tr} (\mathbf{W}^T (\mathbf{x}_i - \boldsymbol{\mu}) \mathbb{E} [\mathbf{z}_i]^T) - \right. \end{aligned}$$

確率の主成分分析 (PPCA)

$$\begin{aligned} & \text{Tr}(\mathbf{W} \mathbb{E}[\mathbf{z}_i \mathbf{z}_i^T] \mathbf{W}^T) \} \\ = & -\frac{1}{2\sigma^2} \sum_i \left(2(\mathbf{x}_i - \boldsymbol{\mu}) \mathbb{E}[\mathbf{z}_i]^T - \mathbf{W} \left(\mathbb{E}[\mathbf{z}_i \mathbf{z}_i^T] + \mathbb{E}[\mathbf{z}_i \mathbf{z}_i^T]^T \right) \right) \\ = & -\frac{1}{2\sigma^2} \sum_i \left(2(\mathbf{x}_i - \boldsymbol{\mu}) \mathbb{E}[\mathbf{z}_i]^T - 2\mathbf{W} \mathbb{E}[\mathbf{z}_i \mathbf{z}_i^T] \right) \\ = & 0 \end{aligned}$$

- ここで、行列に関するトレースの微分の公式を用いた

$$\frac{\partial}{\partial \mathbf{A}} \text{Tr}(\mathbf{A}\mathbf{B}) = \mathbf{B}^T \quad (22)$$

$$\frac{\partial}{\partial \mathbf{A}} \text{Tr}(\mathbf{A}^T \mathbf{B}) = \mathbf{B} \quad (23)$$

$$\frac{\partial}{\partial \mathbf{A}} \text{Tr}(\mathbf{A}^T \mathbf{B} \mathbf{A}) = (\mathbf{B} + \mathbf{B}^T) \mathbf{A} \quad (24)$$

$$\frac{\partial}{\partial \mathbf{A}} \text{Tr}(\mathbf{A} \mathbf{B} \mathbf{A}^T) = \mathbf{A} (\mathbf{B} + \mathbf{B}^T) \quad (25)$$

確率の主成分分析 (PPCA)

- 上式をパラメータ \mathbf{W} について解く

$$\begin{aligned} & -\frac{1}{2\sigma^2} \sum_i \left(2(\mathbf{x}_i - \boldsymbol{\mu}) \mathbb{E}[\mathbf{z}_i]^T - 2\mathbf{W} \mathbb{E}[\mathbf{z}_i \mathbf{z}_i^T] \right) = 0 \\ \Rightarrow & \mathbf{W} \left(\sum_i \mathbb{E}[\mathbf{z}_i \mathbf{z}_i^T] \right) = \sum_i (\mathbf{x}_i - \boldsymbol{\mu}) \mathbb{E}[\mathbf{z}_i]^T \\ \Rightarrow & \mathbf{W} = \left(\sum_i (\mathbf{x}_i - \boldsymbol{\mu}) \mathbb{E}[\mathbf{z}_i]^T \right) \left(\sum_i \mathbb{E}[\mathbf{z}_i \mathbf{z}_i^T] \right)^{-1} \end{aligned} \quad (26)$$

- これより、パラメータ \mathbf{W} の更新式は次のようになる

$$\mathbf{W}_{\text{new}} \leftarrow \left(\sum_i (\mathbf{x}_i - \bar{\mathbf{x}}) \mathbb{E}[\mathbf{z}_i]^T \right) \left(\sum_i \mathbb{E}[\mathbf{z}_i \mathbf{z}_i^T] \right)^{-1} \quad (27)$$

確率の主成分分析 (PPCA)

- σ^2 について偏微分し、0 と等置すると次のようになる

$$\begin{aligned} & \frac{\partial}{\partial \sigma^2} \mathbb{E} [\ln p(\mathbf{X}, \mathbf{Z} | \mathbf{W}, \boldsymbol{\mu}, \sigma^2)] \\ = & \frac{\partial}{\partial \sigma^2} \sum_i \left\{ -\frac{D}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \|\mathbf{x}_i - \boldsymbol{\mu}\|^2 + \right. \\ & \left. \frac{1}{\sigma^2} \mathbb{E} [\mathbf{z}_i]^T \mathbf{W}^T (\mathbf{x}_i - \boldsymbol{\mu}) - \frac{1}{2\sigma^2} \text{Tr} (\mathbb{E} [\mathbf{z}_i \mathbf{z}_i^T] \mathbf{W}^T \mathbf{W}) \right\} \\ = & \sum_i \left\{ -\frac{D}{2} \frac{2\pi}{2\pi\sigma^2} + \frac{1}{2\sigma^4} \|\mathbf{x}_i - \boldsymbol{\mu}\|^2 - \right. \\ & \left. \frac{1}{\sigma^4} \mathbb{E} [\mathbf{z}_i]^T \mathbf{W}^T (\mathbf{x}_i - \boldsymbol{\mu}) + \frac{1}{2\sigma^4} \text{Tr} (\mathbb{E} [\mathbf{z}_i \mathbf{z}_i^T] \mathbf{W}^T \mathbf{W}) \right\} \\ = & -\frac{ND}{2} \frac{1}{\sigma^2} + \sum_i \left\{ \frac{1}{2\sigma^4} \|\mathbf{x}_i - \boldsymbol{\mu}\|^2 - \right. \\ & \left. \frac{1}{\sigma^4} \mathbb{E} [\mathbf{z}_i]^T \mathbf{W}^T (\mathbf{x}_i - \boldsymbol{\mu}) + \frac{1}{2\sigma^4} \text{Tr} (\mathbb{E} [\mathbf{z}_i \mathbf{z}_i^T] \mathbf{W}^T \mathbf{W}) \right\} = 0 \end{aligned}$$

確率の主成分分析 (PPCA)

- 上式をパラメータ σ^2 について解く

$$\begin{aligned} & -ND\sigma^2 + \sum_i \left\{ \|x_i - \mu\|^2 - 2\mathbb{E}[z_i]^T W^T (x_i - \mu) + \right. \\ & \quad \left. \text{Tr}(\mathbb{E}[z_i z_i^T] W^T W) \right\} = 0 \\ \Rightarrow \quad & \sigma^2 = \frac{1}{ND} \sum_i \left\{ \|x_i - \mu\|^2 - 2\mathbb{E}[z_i]^T W^T (x_i - \mu) + \right. \\ & \quad \left. \text{Tr}(\mathbb{E}[z_i z_i^T] W^T W) \right\} \end{aligned} \quad (28)$$

- これより、パラメータ σ^2 の更新式は次のようになる

$$\begin{aligned} \sigma_{\text{new}}^2 \leftarrow & \frac{1}{ND} \sum_i \left\{ \|x_i - \bar{x}\|^2 - 2\mathbb{E}[z_i]^T W_{\text{new}}^T (x_i - \bar{x}) + \right. \\ & \left. \text{Tr}(\mathbb{E}[z_i z_i^T] W_{\text{new}}^T W_{\text{new}}) \right\} \end{aligned} \quad (29)$$

確率的主成分分析 (PPCA)

- 以上で、観測データ $\mathcal{D} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ から、主成分分析のパラメータ \mathbf{W}, σ^2 を推定するための EM アルゴリズムが得られた
- M ステップのパラメータの更新では、E ステップで求めた $\mathbb{E}[z_i]$ と $\mathbb{E}[z_i z_i^T]$ を使用している
- これらの更新式を改良することで、**オンライン型**の EM アルゴリズムを導出することも可能である

- 1 EM アルゴリズムの例
 - 確率的主成分分析 (PPCA)
 - 確率的主成分分析 (PPCA) のまとめ

確率的主成分分析 (PPCA) のまとめ

EM アルゴリズムによる確率的主成分分析モデルの推定

- 目的は、確率的主成分分析モデルが与えられているとき、そのパラメータ (W, μ, σ^2) について、尤度関数 $\ln p(X|W, \mu, \sigma^2)$ を最大化することである

- 1 **μ の決定:** μ を、観測データ x の標本平均として求める (これ以降、 μ は既知として扱い、 \bar{x} と書く)

$$\mu = \bar{x} = \frac{1}{N} \sum_i x_i \quad (30)$$

- 2 **初期化:** パラメータ $W_{\text{old}}, \sigma_{\text{old}}^2$ を適当に初期化し、対数尤度 $\ln p(X|W, \sigma^2)$ の初期値を計算する

確率的主成分分析 (PPCA) のまとめ

3 Eステップ: 現在のパラメータを用いて、以下の量を計算する

$$\mathbb{E}[\mathbf{z}_i] = \mathbf{M}^{-1} \mathbf{W}_{\text{old}}^T (\mathbf{x}_i - \bar{\mathbf{x}}) \quad (31)$$

$$\mathbb{E}[\mathbf{z}_i \mathbf{z}_i^T] = \sigma_{\text{old}}^2 \mathbf{M}^{-1} + \mathbb{E}[\mathbf{z}_i] \mathbb{E}[\mathbf{z}_i]^T \quad (32)$$

但し

$$\mathbf{M} = \mathbf{W}_{\text{old}}^T \mathbf{W}_{\text{old}} + \sigma_{\text{old}}^2 \mathbf{I} \quad (33)$$

確率的主成分分析 (PPCA) のまとめ

- 4 **M ステップ**: 現在の $\mathbb{E}[z_i]$ と $\mathbb{E}[z_i z_i^T]$ を用いて、パラメータを更新する

$$\mathbf{W}_{\text{new}} \leftarrow \left(\sum_i (\mathbf{x}_i - \bar{\mathbf{x}}) \mathbb{E}[z_i]^T \right) \left(\sum_i \mathbb{E}[z_i z_i^T] \right)^{-1} \quad (34)$$

$$\sigma_{\text{new}}^2 \leftarrow \frac{1}{ND} \sum_i \left\{ \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2 - 2 \mathbb{E}[z_i]^T \mathbf{W}_{\text{new}}^T (\mathbf{x}_i - \bar{\mathbf{x}}) + \text{Tr}(\mathbb{E}[z_i z_i^T] \mathbf{W}_{\text{new}}^T \mathbf{W}_{\text{new}}) \right\} \quad (35)$$

確率的主成分分析 (PPCA) のまとめ

- 5 対数尤度関数 $\ln p(\mathbf{X}|\mathbf{W}, \boldsymbol{\mu}, \sigma^2)$ を計算する

$$\begin{aligned} & \ln p(\mathbf{X}|\mathbf{W}, \boldsymbol{\mu}, \sigma^2) \\ = & -\frac{ND}{2} \ln 2\pi - \frac{N}{2} \ln |\mathbf{C}| - \frac{1}{2} \sum_i (\mathbf{x}_i - \bar{\mathbf{x}})^T \mathbf{C}^{-1} (\mathbf{x}_i - \bar{\mathbf{x}}) \end{aligned}$$

但し

$$\mathbf{C} = \mathbf{W}_{\text{new}} \mathbf{W}_{\text{new}}^T + \sigma_{\text{new}}^2 \mathbf{I} \quad (36)$$

パラメータの変化量、あるいは対数尤度の変化量をみて、収束性を判定する

- 6 収束基準を満たしていなければ、(3) に戻る

$$\mathbf{W}_{\text{old}} \leftarrow \mathbf{W}_{\text{new}}, \quad \sigma_{\text{old}}^2 \leftarrow \sigma_{\text{new}}^2 \quad (37)$$